

Estadística

Práctica 3

Estadística descriptiva con dos variables

Contenido

1. Introducción	3
1.1 Creación de una variable estadística auxiliar	3
2. Covarianza y coeficiente de correlación	5
Ejemplos	5
3. Diagrama de dispersión	6
Ejemplos	6
4. Tablas de contingencia	9
Ejemplos	10
5. Cálculo de medidas estadísticas marginales con varias variables	15
Ejemplos	15
6. Cálculo de medidas estadísticas condicionadas con dos variables	17
Ejemplos	17
7. Otros diagramas con dos variables	20
Ejemplos	20
8. Ejercicios propuestos	24

1. Introducción

Con esta práctica se trata de utilizar R y RStudio para calcular medidas estadísticas sobre dos variables, para analizar las posibles relaciones entre ellas.

Se usarán en los ejemplos los datos suministrados por los estudiantes de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá. Con las siguientes variables estadísticas:

- GRUPO: Grupo de laboratorio
- GRADO: Orden de preferencia elegido para el Grado en Ingeniería en Sistemas de Información por la Universidad de Alcalá
- NOTA: Nota final de acceso a la universidad
- VIAJE: Tiempo en llegar a la Escuela Politécnica en minutos
- DORMIR: Horas que se duerme los días laborables
- MOVIL: Compañía de la línea móvil
- SO: Sistema operativo del móvil

GRUPO	GRADO	NOTA	VIAJE	DORMIR	MOVIL	SO
A1	Quinta opcion	8,5	75		7 Movistar/O2/Android	
A1	Quinta opcion	7,1	90		7 Movistar/O2/iOS	
A1	Segunda opcion	8,63	60		6 Digi Mobil	Android
A1	Segunda opcion	8,62	35		8 Movistar/O2/iOS	
A1	Tercera opcion	8,2	120		7 Movistar/O2/Android	
A1	Primera opcion	8,7	20		7 Jazztel/Orang	Android
A1	Primera opcion	7,21	20		6 Movistar/O2/Android	
A1	Segunda opcion	7,63	20		8 Movistar/O2/Android	
A1	Quinta opcion	8,4	60		7 Lowi/Vodafone iOS	
A1	Quinta opcion	8,3	90		6 Lowi/Vodafone iOS	
A1	Tercera opcion	8,2	60		6 Lowi/Vodafone iOS	
A1	Quarta opcion	9,1	75		7 Jazztel/Orang	Android

Para evitar problemas, se han borrado las filas en las que había algún valor vacío, y el fichero resultante se encuentre en "[encuesta.csv](#)".

Se debe cargar el fichero encuesta.csv en una variable de tipo data.frame usando la función read.csv2(), preparada para leer fichero csv con columnas separadas por ";" y decimales con ",".

```
> (encuesta = read.csv2("encuesta.csv"))
```

1.1 Creación de una variable estadística auxiliar

Cuando hay que realizar un análisis estadístico, es posible que haya que crear nuevas variables estadísticas auxiliares, a partir de alguna de las variables estadísticas disponibles en el archivo de datos.

Por ejemplo, en el archivo de la encuesta, la variable GRUPO indica si un estudiante pertenece a uno de cuatro grupos posibles: A1, A2, B1, B2. Si los grupos A1 y A2 son del turno de mañana y los grupos B1 y B2 son del turno de tarde, podría interesar crear una nueva variable estadística auxiliar que representase el TURNO, con los posibles valores “Mañana” o “Tarde”.

Con los siguientes comandos se crea una variable de tipo tabla con una nueva columna TURNO.

```
> encuesta.mañana=encuesta[(encuesta$GRUPO=="A1")|(encuesta$GRUPO=="A2")),]
> encuesta.tarde=encuesta[(encuesta$GRUPO=="B1")|(encuesta$GRUPO=="B2")),]

> encuesta.mañana$TURNO=rep(c("Mañana"),times=nrow(encuesta.mañana))
> encuesta.tarde$TURNO=rep(c("Tarde"),times=nrow(encuesta.tarde))

> encuesta.con.turno=rbind(encuesta.mañana, encuesta.tarde)
```

Puede visualizarse el contenido de la nueva variable creada en forma de tabla:

```
> View(encuesta.con.turno)
```

	GRUPO	GRADO	NOTA	VIAJE	DORMIR	MOVIL	SO	TURNO
1	A1	Quinta opcion o superior	8.50	75	7	Movistar/O2/Tuenti	Android	Mañana
2	A1	Quinta opcion o superior	7.10	90	7	Movistar/O2/Tuenti	iOS	Mañana
3	A1	Segunda opcion	8.63	60	6	Digi Mobil	Android	Mañana
4	A1	Segunda opcion	8.62	35	8	Movistar/O2/Tuenti	iOS	Mañana
5	A1	Tercera opcion	8.20	120	7	Movistar/O2/Tuenti	Android	Mañana
6	A1	Primera opcion	8.70	20	7	Jazztel/Orange/Simyo	Android	Mañana
7	A1	Primera opcion	7.21	20	6	Movistar/O2/Tuenti	Android	Mañana
8	A1	Segunda opcion	7.63	20	8	Movistar/O2/Tuenti	Android	Mañana
9	A1	Quinta opcion o superior	8.40	60	7	Lowi/Vodafone	iOS	Mañana

2. Covarianza y coeficiente de correlación

Las funciones para calcular la covarianza y el coeficiente de correlación entre dos variables son las que se indican en la siguiente tabla:

Operación	R	Comentarios
Covarianza	<code>cov(x, y)</code>	Las variables deben ser numéricas y tener la misma longitud (valores).
Matriz de covarianzas	<code>cov(dataframe)</code>	En dataframe solo puede haber variables numéricas.
Coeficiente de correlación (de Pearson)	Si no hay valores nulos: <code>cor(x, y)</code> Si hay valores nulos: <code>cor(x, y, use="...")</code>	Las variables deben ser numéricas y tener la misma longitud (valores). Para valores nulos consultar la ayuda de RStudio sobre el argumento "use".
Coeficiente de correlación de Kendall	<code>cor(x, y, method="kendall")</code>	
Coeficiente de correlación de Spearman	<code>cor(x, y, method="spearman")</code>	
Matriz de correlaciones	<code>cor(dataframe)</code>	En dataframe solo puede haber variables numéricas.

Ejemplos

1) Correlación entre las variables VIAJE y DORMIR

```
> cor(encuesta$VIAJE, encuesta$DORMIR)
[1] -0.1408408
```

2) Matriz de correlaciones (se crea un data frame con las variables numéricas)

```
> encuesta.num = data.frame(encuesta$NOTA, encuesta$VIAJE, encuesta$DORMIR)
> cor(encuesta.num)
          encuesta.NOTA encuesta.VIAJE encuesta.DORMIR
encuesta.NOTA    1.00000000    -0.1238763    0.07318059
encuesta.VIAJE   -0.12387633     1.0000000   -0.14084079
encuesta.DORMIR    0.07318059   -0.1408408    1.00000000
```

3) Matriz de covarianzas

```
> cov(encuesta.num)
          encuesta.NOTA encuesta.VIAJE encuesta.DORMIR
encuesta.NOTA    1.27937984    -5.194600    0.07572436
encuesta.VIAJE   -5.19460015   1374.447242   -4.77674935
encuesta.DORMIR    0.07572436    -4.776749    0.83691225
```

3. Diagrama de dispersión

Se obtienen con el código R que se indica en la siguiente tabla¹:


Operación	R	Comentarios
Diagrama de dispersión de la variable y en función de la variable x	<code>plot(x, y)</code>	
Recta de regresión de y en función de x: $y = a + bx$ Método 1: Calculando coeficientes	<code>b=cov(x, y) / var(x)</code> <code>a=mean(y) -b*mean(x)</code> <code>plot(x, y)</code> <code>abline(a, b)</code>	$b = \frac{Cov(x, y)}{S_x^2}$ $a = \bar{y} - b\bar{x}$
Recta de regresión de y en función de x: $y = a + bx$ Método 2: Calculando modelo de regresión lineal	<code>mod.reg.lineal=lm(y ~ x)</code> <code>plot(x, y)</code> <code>abline(mod.reg.lineal)</code>	El símbolo ~ se obtiene con: - Alt + 126 con teclado numérico - Alt Gr + 4 con teclado normal - Alt+ñ (Mac)
Ver coeficientes de la recta de regresión usando el modelo	<code>mod.reg.lineal\$coefficients</code>	
Resumen del modelo	<code>summary(mod.reg.lineal)</code>	
Predecir un valor de y a partir de un valor de x	<code>valor.y=a+b*valor.x</code>	Se aplica la fórmula de la recta de regresión.

Ejemplos

1) Diagrama de dispersión de DORMIR en función de VIAJE


```
> plot(encuesta$VIAJE, encuesta$DORMIR)
```

¹ Aunque la recta de regresión forma parte de la estadística inferencial, se incluye en esta práctica sobre estadística descriptiva a efectos informativos para conocer las funciones que ofrece R sobre ello, ya que no se ha previsto realizar una práctica específica para modelos de regresión.




2) Recta de regresión de DORMIR en función de VIAJE (calculando coeficientes)

```
> x=encuesta$VIAJE
> y=encuesta$DORMIR
> plot(x,y)
> (b=cov(x,y)/var(x))
[1] -0.003475397
> (a=mean(y)-b*mean(x))
[1] 6.98969
> abline(a, b)
```



3) Recta de regresión de DORMIR en función de VIAJE (calculando modelo lineal)

```
> x=encuesta$VIAJE
> y=encuesta$DORMIR
> plot(x,y)
> mod.reg.lineal=lm(y ~ x)
> abline(mod.reg.lineal)
```



4) Ver coeficientes de la recta de regresión usando el modelo

```
> mod.reg.lineal$coefficients
```

```
(Intercept)          x  
6.989689908 -0.003475397
```

- 5) Si una persona tardase 150 minutos en viajar a la escuela, ¿Cuántas horas duerme? Se trata de predecir el valor de la variable DORMIR (y) a partir de la variable VIAJE (x), usando la fórmula de la recta de regresión: $y=a+bx$.

```
> x=encuesta$VIAJE  
> y=encuesta$DORMIR  
> b=cov(x,y)/var(x)  
> a=mean(y)-b*mean(x)  
>  
> a+b*150  
[1] 6.46838
```


4. Tablas de contingencia

Una tabla de contingencia es una tabla de frecuencias para una variable estadística bidimensional, en la que aparecen las frecuencias para las combinaciones de valores de las dos variables que forman la variable bidimensional.

Las principales tablas de frecuencias se obtienen como se indica en la siguiente tabla:

Operación	R	Comentarios
Tabla de frecuencias absolutas de dos variables	<code>table(x, y)</code>	Los valores de x son los nombres de las filas. Los valores de y son los nombres de las columnas
Tabla de frecuencias relativas	<code>prop.table(table(x, y))</code>	Se calcula dividiendo las absolutas por el número total de combinaciones (x,y) de la tabla.
Tabla de frecuencias relativas condicionadas	<code>prop.table(table(x, y), n)</code>	Si n=1 calcula las frecuencias relativas de la variable y condicionada a los valores de x. La suma de las frecuencias de cada fila es 1. Si n=2 calcula las frecuencias relativas de la variable x condicionada a los valores de y. La suma de las frecuencias de cada columna es 1.
Tabla de frecuencias absolutas que incluye frecuencias marginales (márgenes)	<code>addmargins(table(x, y))</code>	
Tabla de frecuencias relativas que incluye frecuencias marginales	<code>addmargins(prop.table(table(x, y)))</code>	
Tabla de frecuencias relativas condicionadas que incluye frecuencias marginales	<code>addmargins(prop.table(table(x, y), n))</code>	n=1 o n=2
Obtener frecuencias marginales a partir de una tabla de frecuencias absolutas	<code>margin.table(table(x, y), margin=n)</code>	Si n=1 devuelve una tabla con las frecuencias absolutas marginales de la primera variable (x) Si n=2 devuelve una tabla con las frecuencias

Operación	R	Comentarios
		absolutas marginales de la segunda variable (y)
Obtener frecuencias marginales a partir de una tabla de frecuencias relativas	<code>margin.table(prop.table(table(x,y)), margin=n)</code>	n=1 o n=2

Ejemplos

- 1) Tabla de frecuencias absolutas de las variables GRUPO y SO, y con frecuencias absolutas marginales

```
> (t.abs.grupo.so=table(encuesta$GRUPO, encuesta$SO))
```

```
      Android iOS
A1         14   9
A2         13   6
B1         12   7
B2         11   2
```

```
> addmargins(t.abs.grupo.so)
```

```
      Android iOS Sum
A1         14   9  23
A2         13   6  19
B1         12   7  19
B2         11   2  13
Sum         50  24  74
```

- 2) Tabla de frecuencias relativas de la variables GRUPO y SO, y con frecuencias relativas marginales

```
> (t.rel.grupo.so=prop.table(t.abs.grupo.so))
```

```
      Android      iOS
A1 0.18918919 0.12162162
A2 0.17567568 0.08108108
B1 0.16216216 0.09459459
B2 0.14864865 0.02702703
```

```
> addmargins(t.rel.grupo.so)
```

```
      Android      iOS      Sum
A1 0.18918919 0.12162162 0.31081081
A2 0.17567568 0.08108108 0.25675676
B1 0.16216216 0.09459459 0.25675676
B2 0.14864865 0.02702703 0.17567568
Sum 0.67567568 0.32432432 1.00000000
```

3) Tabla de contingencia de la variable GRUPO condicionada a la variable SO

Se trata de dibujar una tabla con las frecuencias absolutas, las frecuencias absolutas marginales (f) y las frecuencias relativas marginales (h) obtenidas en los dos apartados anteriores.

GRUPO/SO	Android	iOS	f_{GRUPO}	h_{GRUPO}
A1	14	9	23	0.31081081
A2	13	6	19	0.25675676
B1	12	7	19	0.25675676
B2	11	2	13	0.17567568
f_{SO}	50	24	74	
h_{SO}	0.67567568	0.32432432		1

4) Tabla de frecuencias relativas de la variable SO condicionada a la variable GRUPO, y con frecuencias marginales (la suma de cada fila debe ser 1 en la columna de frecuencia marginal)

```
> (t.rel.cond.grupo=prop.table(t.abs.grupo.so,1))
```

```
      Android      iOS
A1 0.6086957 0.3913043
A2 0.6842105 0.3157895
B1 0.6315789 0.3684211
B2 0.8461538 0.1538462
```

```
> addmargins(t.rel.cond.grupo)
```

```
      Android      iOS      Sum
A1 0.6086957 0.3913043 1.0000000
A2 0.6842105 0.3157895 1.0000000
B1 0.6315789 0.3684211 1.0000000
B2 0.8461538 0.1538462 1.0000000
Sum 2.7706390 1.2293610 4.0000000
```

5) Tabla de frecuencias relativas de la variable GRUPO condicionada a la variable SO, y con frecuencias marginales (la suma de cada columna debe ser 1 en la fila de frecuencia marginal)

```
> (t.rel.cond.so=prop.table(t.abs.grupo.so,2))
```

```
      Android      iOS
A1 0.28000000 0.37500000
A2 0.26000000 0.25000000
B1 0.24000000 0.29166667
B2 0.22000000 0.08333333
```

```
> addmargins(t.rel.cond.so)
```

```
      Android      iOS      Sum
A1 0.28000000 0.37500000 0.65500000
A2 0.26000000 0.25000000 0.51000000
```

```
B1 0.24000000 0.29166667 0.53166667
B2 0.22000000 0.08333333 0.30333333
Sum 1.00000000 1.00000000 2.00000000
```

- 6) Obtener las frecuencias marginales a partir de las frecuencias absolutas y relativas de la variable GRUPO.

```
> margin.table(t.abs.grupo.so,margin=1)
```

```
A1 A2 B1 B2
23 19 19 13
```

```
> margin.table(t.rel.grupo.so,margin=1)
```

```
      A1      A2      B1      B2
0.3108108 0.2567568 0.2567568 0.1756757
```

- 7) Obtener las frecuencias marginales a partir de las frecuencias absolutas y relativas de la variable SO.

```
> margin.table(t.abs.grupo.so,margin=2)
```

```
Android   iOS
      50      24
```

```
> margin.table(t.rel.grupo.so,margin=2)
```

```
Android   iOS
0.6756757 0.3243243
```

- 8) Tabla de frecuencias absolutas para las variables TURNO y SO, y con frecuencias absolutas marginales.

En el apartado 1.1 de esta práctica se había creado una variable `encuesta.con.turno`, que contenía una nueva columna TURNO que representaba una variable estadística auxiliar, que indicaba si un estudiante pertenece al turno de Mañana (cuando está en el grupo A1 o A2) o al grupo de Tarde (cuando está en el grupo B1 o B2).

```
> (t.abs.turno.so=table(encuesta.con.turno$TURNO,encuesta.con.turno$SO))
```

```
      Android iOS
Mañana      27  15
Tarde       23   9
```

```
> addmargins(t.abs.turno.so)
```

```
      Android iOS Sum
Mañana      27  15  42
Tarde       23   9  32
Sum         50  24  74
```

9) Tabla de frecuencias relativas de las variables TURNO y SO, y con frecuencias relativas marginales

```
> (t.rel.turno.so=prop.table(t.abs.turno.so))
```

```
      Android      iOS
Mañana 0.3648649 0.2027027
Tarde  0.3108108 0.1216216
```

```
> addmargins(t.rel.turno.so)
```

```
      Android      iOS      Sum
Mañana 0.3648649 0.2027027 0.5675676
Tarde  0.3108108 0.1216216 0.4324324
Sum     0.6756757 0.3243243 1.0000000
```

10) Tabla de contingencia de la variable TURNO condicionada a la variable SO

Se trata de dibujar una tabla con las frecuencias absolutas, las frecuencias absolutas marginales (f) y las frecuencias relativas marginales (h) obtenidas en los dos apartados anteriores. Para simplificar, redondeamos a dos decimales las frecuencias relativas.

TURNO/SO	Android	iOS	f_{TURNO}	h_{TURNO}
Mañana	27	15	42	0.57
Tarde	23	9	32	0.43
f_{so}	50	24	74	
h_{so}	0.68	0.32		1

11) Tabla de contingencia de la variable NOTA agrupada en intervalos de clase, condicionada a la variable SO.

Hay que decidir los intervalos de clase en los que agrupar las notas. Podemos agrupar en un número de intervalos o clases cercano al recomendando por la regla de Sturges, que en este caso es 8:

```
> #Regla de Sturges para una muestra de tamaño 74
> ceiling(1+3.322*log10(74))
[1] 8
```

Un número razonable de intervalos en este caso serían 6 intervalos iguales de 1 punto cada uno, desde la nota 5 hasta 11.

La tabla de contingencia para nota y turno con frecuencias absolutas se obtendría con los siguientes comandos:

```
> #Tabla de contingencia con 6 clases
> L=c(5,6,7,8,9,10,11)
> nota.agrupada=cut(encuesta$NOTA, breaks=L, right=FALSE, include.lowest = TRUE)
> addmargins(table(nota.agrupada, encuesta$SO))
```

```
nota.agrupada Android iOS Sum
[5,6)           2    0    2
[6,7)           5    4    9
[7,8)          22    9   31
[8,9)          12    6   18
[9,10)          7    0    7
[10,11]         2    5    7
Sum             50   24   74
```

```
> round(addmargins(prop.table(table(nota.agrupada, encuesta$SO))), 2)
```

```
nota.agrupada Android iOS Sum
[5,6)           0.03 0.00 0.03
[6,7)           0.07 0.05 0.12
[7,8)           0.30 0.12 0.42
[8,9)           0.16 0.08 0.24
[9,10)          0.09 0.00 0.09
[10,11]         0.03 0.07 0.09
Sum             0.68 0.32 1.00
```

La tabla de contingencia sería la siguiente:

NOTA/SO	Android	iOS	f_{NOTA}	h_{NOTA}
[5, 6)	2	0	2	0.03
[6, 7)	5	4	9	0.12
[7, 8)	22	9	31	0.42
[8, 9)	12	6	18	0.24
[9, 10)	7	0	7	0.09
[10, 11]	2	5	7	0.09
f_{SO}	50	24	74	
h_{SO}	0.68	0.32		1

5. Cálculo de medidas estadísticas marginales con varias variables

Se trata de calcular las medidas de cada variable de forma independiente, sin tener en cuenta el valor de las otras variables.

Operación	R	Comentarios
Resumen	<code>summary(dataframe)</code>	En dataframe están las variables
Medias marginales	<code>sapply(dataframe, mean)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code>
Medianas marginales	<code>sapply(dataframe, median)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code>
Modas marginales	<code>sapply(dataframe, moda)</code>	Debe crearse previamente la función <code>moda()</code> . Si puede haber valores no válidos, se puede usar <code>na.omit(dataframe)</code>
Varianzas marginales	<code>sapply(dataframe, var)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code>
Desviaciones estándar marginales	<code>sapply(dataframe, sd)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code>
Cuartiles marginales	<code>sapply(dataframe, quantile, mean)</code>	En dataframe solo puede haber variables numéricas.

Ejemplos

1) Resumen

```
> summary(encuesta)
GRUPO          GRADO          NOTA          VIAJE          DORMIR          MOVIL          SO
Length:74      Length:74      Min.   : 5.800    Min.   : 5.00    Min.   :4.00    Length:74      Length:74
Class :character Class :character 1st Qu.: 7.275    1st Qu.: 30.00   1st Qu.:6.00    Class :character Class :character
Mode  :character Mode  :character Median : 7.815    Median : 60.00   Median :7.00    Mode  :character Mode  :character
Mean   : 8.023    Mean   : 63.14   Mean   :6.77
3rd Qu.: 8.598    3rd Qu.: 90.00   3rd Qu.:7.00
Max.   :10.800    Max.   :180.00   Max.   :9.00
```

2) Medias

```
> sapply(encuesta, mean)
GRUPO          GRADO          NOTA          VIAJE          DORMIR          MOVIL          SO
NA          NA      8.022568  63.135135   6.770270          NA          NA
```

3) Medianas

```
> sapply(encuesta,median)
GRUPO GRADO  NOTA  VIAJE DORMIR  MOVIL      SO
      NA      NA  7.815 60.000  7.000      NA      NA
```

4) Modas

```
> moda = function (x) {
+   u = unique(x)
+   m = match(x,u)
+   t = tabulate(m)
+   return (u[t == max(t)])
+ }

> sapply(encuesta,moda)
GRUPO GRADO  NOTA  VIAJE
"A1"      "Primera opcion"  "7.8"  "120"
DORMIR      MOVIL      SO
"7" "Jazztel/Orange/Simyo"  "Android"
```

5) Varianzas

```
> sapply(encuesta,var)
GRUPO GRADO  NOTA  VIAJE  DORMIR  MOVIL  SO
      NA      NA  1.2803837 1374.4472418  0.8369123      NA      NA
```

6) Desviaciones estándar

```
> sapply(encuesta,sd)
GRUPO GRADO  NOTA  VIAJE  DORMIR  MOVIL  SO
      NA      NA  1.1315404 37.0735383  0.9148291      NA      NA
```

7) Cuartiles

```
> encuesta.num=data.frame(encuesta$NOTA,encuesta$VIAJE,encuesta$DORMIR)
> sapply(encuesta.num,quantile)
      encuesta.NOTA encuesta.VIAJE encuesta.DORMIR
0%           5.8000           5           4
25%          7.2750          30           6
50%          7.8150          60           7
75%          8.5975          90           7
100%         10.8000         180           9
```


6. Cálculo de medidas estadísticas condicionadas con dos variables

Se trata de calcular las medidas de una variable cuantitativa cuando otra variable (cuantitativa o cualitativa) tiene un valor determinado.

Operación	R	Comentarios
Medias condicionadas	<code>tapply (var1, var2, mean)</code>	Media de la variable var1 para cada valor de la variable var2. La variable var1 debe ser numérica. Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code> .
Medianas condicionadas	<code>tapply (var1, var2, median)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code> .
Modas condicionadas	<code>tapply (var1, var2, moda)</code>	Debe crearse previamente la función <code>moda()</code> .
Varianzas condicionadas	<code>tapply (var1, var2, var)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code> .
Desviaciones estándar condicionadas	<code>tapply (var1, var2, sd)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code> .
Cuartiles condicionados	<code>tapply (var1, var2, quantile)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code> .
Método alternativo	<code>aggregate(var1,by=list(var2),mean)</code> <code>aggregate(var1,by=list(var2),median)</code> <code>aggregate(var1,by=list(var2),moda)</code> <code>aggregate(var1,by=list(var2),var)</code> <code>aggregate(var1,by=list(var2),sd)</code> <code>aggregate(var1,by=list(var2),quantile)</code>	Si puede haber valores no válidos, se puede añadir el parámetro <code>na.rm=TRUE</code> .

Ejemplos

- 1) Medias, medianas, modas, varianzas, desviaciones estándar y cuartiles de la variable VIAJE para cada valor de la variable GRUPO

```
> tapply(encuesta$VIAJE, encuesta$GRUPO, mean)
      A1      A2      B1      B2
59.13043 61.68421 70.36842 61.76923

> tapply(encuesta$VIAJE, encuesta$GRUPO, median)
A1 A2 B1 B2
60 75 60 55
```

```
> tapply(encuesta$VIAJE, encuesta$GRUPO, moda)
$A1
[1] 90 60

$A2
[1] 20 80

$B1
[1] 45

$B2
[1] 90 120

> tapply(encuesta$VIAJE, encuesta$GRUPO, var)
      A1      A2      B1      B2
1283.300 1423.339 1613.135 1334.859

> tapply(encuesta$VIAJE, encuesta$GRUPO, sd)
      A1      A2      B1      B2
35.82318 37.72717 40.16385 36.53572

> tapply(encuesta$VIAJE, encuesta$GRUPO, quantile)
$A1
 0%  25%  50%  75% 100%
 5   30   60   90  120

$A2
 0%  25%  50%  75% 100%
15   20   75   90  120

$B1
 0%  25%  50%  75% 100%
10.0 45.0 60.0 92.5 180.0

$B2
 0%  25%  50%  75% 100%
10   38   55   90  120
```

2) Medias, medianas, modas, varianzas, desviaciones estándar y cuartiles de la variable VIAJE para cada valor de la variable TURNO

Se usará la variable `encuesta.con.turno` creada en el apartado 1.1, que contiene una nueva columna TURNO.

```
> tapply(encuesta.con.turno$VIAJE, encuesta.con.turno$TURNO, mean)
Mañana Tarde
60.28571 66.87500

> tapply(encuesta.con.turno$VIAJE, encuesta.con.turno$TURNO, median)
Mañana Tarde
 60    60

> tapply(encuesta.con.turno$VIAJE, encuesta.con.turno$TURNO, moda)
$Mañana
```

```
[1] 90 20
```

```
$Tarde
```

```
[1] 45
```

```
> tapply(encuesta.con.turno$VIAJE, encuesta.con.turno$TURNO, var)
  Mañana      Tarde
1315.136 1471.790
```

```
> tapply(encuesta.con.turno$VIAJE, encuesta.con.turno$TURNO, sd)
  Mañana      Tarde
36.26480 38.36392
```

```
> tapply(encuesta.con.turno$VIAJE, encuesta.con.turno$TURNO, quantile)
$Mañana
  0%   25%   50%   75%  100%
 5.0 22.5 60.0 90.0 120.0
```

```
$Tarde
  0%   25%   50%   75%  100%
10.00 43.75 60.00 90.00 180.00
```

7. Otros diagramas con dos variables

En la siguiente tabla se indican las principales operaciones para obtener diagramas a partir de los datos de frecuencias conjuntas de dos variables estadísticas.

Operación	R	Comentarios
Dividir la ventana gráfica de RStudio en dos columnas	<code>par(mfrow = c(1, 2))</code>	
Volver a pantalla original	<code>par(mfrow = c(1, 1))</code>	
Diagrama de barras agrupadas en vertical	<code>barplot(table(var1,var2))</code>	<code>table(var1,var2)</code> es la tabla de frecuencias conjunta de las dos variables (var1,var2). En la parte inferior del diagrama aparecen los valores de var2.
Diagrama de barras agrupadas en vertical con etiquetas.	<code>barplot(table(var1,var2), xlab="Texto sobre variable var2", col=..., legend.text = rownames(table(var1,var2)))</code>	"col" indica los colores a usar, por ejemplo <code>rainbow(10)</code> o <code>1:10</code> .
Diagrama de barras agrupadas en horizontal	<code>barplot(table(var1,var2), beside = TRUE)</code>	
Gráfico de mosaico	<code>mosaicplot(table(var1,var2), col = ..)</code>	
Diagrama de cajas con datos agrupados	<code>boxplot(var1 ~ var2)</code>	var1 debe ser numérica. El símbolo ~ se obtiene con: - Alt + 126 con teclado numérico - Alt Gr + 4 con teclado normal - Alt+ñ (Mac)

Ejemplos

- 1) Diagramas de barras agrupadas en vertical de las variables GRUPO y SO. A la izquierda cuando x=SO e y=GRUPO. A la derecha cuando x=SO e y =GRUPO


```
> (t.abs.grupo.so=table(encuesta$GRUPO,encuesta$SO))

      Android iOS
A1         14   9
A2         13   6
B1         12   7
B2         11   2
```

```
> (t.abs.so.grupo=table(encuesta$SO, encuesta$GRUPO))
```


```
      A1 A2 B1 B2
Android 14 13 12 11
iOS      9  6  7  2
```

```
> par(mfrow = c(1, 2))
> barplot(t.abs.grupo.so)
> barplot(t.abs.so.grupo)
```





2) Diagramas de barras en vertical con colores y etiquetas

```
> par(mfrow = c(1, 2))
> barplot(t.abs.grupo.so,
+         xlab="Sistema operativo",
+         col=rainbow(4),
+         legend.text = rownames(t.abs.grupo.so))
> barplot(t.abs.so.grupo,
+         xlab="Grupo",
+         col=rainbow(2),
+         legend.text = rownames(t.abs.so.grupo))
```





3) Diagramas de barras agrupadas en horizontal de las variables GRUPO y SO

```
> par(mfrow = c(1, 2))
> barplot(t.abs.grupo.so, beside = TRUE)
> barplot(t.abs.so.grupo, beside = TRUE)
```





4) Diagramas de mosaico de las variables GRUPO y SO

```
> par(mfrow = c(1, 2))
> mosaicplot(t.abs.grupo.so, col = 1:10)
> mosaicplot(t.abs.so.grupo, col = 1:10)
```



5) Diagramas de caja de la variable NOTA según el valor de la variable GRUPO y SO


```
> par(mfrow = c(1, 2))
> boxplot(encuesta$NOTA ~ encuesta$GRUPO)
> boxplot(encuesta$NOTA ~ encuesta$SO)
```



6) Diagramas de caja de la variable NOTA según el valor de la variable TURNO

Se usará la variable `encuesta.con.turno` creada en el apartado 1.1, que contiene una nueva columna TURNO.

```
> boxplot(encuesta.con.turno$NOTA ~ encuesta.con.turno$TURNO)
```



8. Ejercicios propuestos

Resolver los siguientes ejercicios, leyendo previamente el fichero encuesta.csv:

```
encuesta = read.csv2("encuesta.csv")
```

1. Calcular el coeficiente de correlación lineal entre las variables NOTA y DORMIR.
2. Dibujar el diagrama de dispersión y la recta de regresión de la variable NOTA en función de la variable DORMIR, utilizando la función `abline()` con los coeficientes a y b .
3. Predecir el valor de la variable NOTA si el valor de la variable DORMIR es 10 horas.
4. Obtener la tabla de frecuencias absolutas que incluya frecuencias marginales de las variables MOVIL (filas) y SO (columnas).
5. Calcular las medidas (medias, medianas, modas, varianzas, desviaciones estándar, cuartiles) de la variable NOTA condicionada a cada valor de la variable GRADO utilizando la función `tapply()`.
6. Dividir la pantalla en dos partes con la función `par()` y dibujar los diagramas de barras agrupadas en vertical de las variables DORMIR y SO. A la izquierda cuando $x=\text{DORMIR}$ e $y=\text{SO}$. A la derecha cuando $x=\text{SO}$ e $y=\text{DORMIR}$.