

Estadística

Práctica 5

Variables aleatorias y distribuciones discretas

Contenido

1. Introducción	3
2. Variables discretas con distribución binomial	3
3. Variables discretas con distribución hipergeométrica	6
3.1 Aproximación de una variable hipergeométrica a una binomial	8
3.2 Ejemplo (aproximación binomial): Estudiantes que tienen móviles Android	9
4. Variables discretas con distribución de Poisson	16
4.1 Ejemplo: Correo electrónico no deseado (spam)	19
4.2 Aproximar una variable binomial a una distribución de Poisson	24
5. Otras distribuciones discretas	25
6. Ejercicios propuestos	26

1. Introducción

Con esta práctica se utiliza R y RStudio para calcular probabilidades de sucesos a partir de variables discretas que siguen una distribución binomial o una distribución de Poisson.

2. Variables discretas con distribución binomial

Una variable binomial es una variable discreta (X) que representa el número de éxitos (x) obtenidos en n ensayos independientes (de Bernoulli), conociendo la probabilidad (p) de un éxito.

Se representa como $X:B(n,p)$. Y se dice que la variable tiene una distribución binomial.



Por ejemplo, una variable $X:B(10,0.5)$ que representa: “Número de caras (éxitos) al lanzar 10 veces una moneda ($n=10$), sabiendo que la probabilidad de que salga cara (éxito) en cada tirada es del 50% ($p=0.5$)”.

En R se pueden utilizar las funciones indicadas en la siguiente tabla. En la columna “Ejemplo de uso”, se utiliza una variable $B(10,0.5)$.

Función	Código R	Resultado	Ejemplo de uso
Masa de probabilidad $P\{X=x\}$	<code>dbinom(x, n, p)</code>	Calcula la probabilidad de que una variable aleatoria binomial $X:B(n,p)$ tenga el valor x .	<pre>>dbinom(3,10,0.5) [1] 0.1171875</pre>
Distribución acumulada $F(X)=P\{X\leq x\}$	<code>pbinom(x, n, p)</code>	Calcula la probabilidad de que una variable aleatoria binomial $X:B(n,p)$ tenga un valor igual o menor que x .	<pre>>pbinom(3,10,0.5) [1] 0.171875</pre>
Cuantil	<code>qbinom(q, n, p)</code>	Calcula el menor valor de una variable aleatoria binomial $X:B(n,p)$, que cumple que la probabilidad de que la variable sea menor o igual a ese valor, es mayor o igual a q .	<pre>>qbinom(0.7,10,0.5) [1] 6</pre> Entonces se cumple: $P\{X\leq 6\} \geq 0.7$ Pero no se cumple: $P\{X\leq 5\} \geq 0.7$
Generación aleatoria de muestras	<code>rbinom(m, n, p)</code>	Genera aleatoriamente un vector de m valores aleatorios de una variable binomial $X:B(n,p)$. Cada valor representa el número de éxitos en cada simulación del experimento.	<pre>>rbinom(4,10,0.5) [1] 6 7 7 8</pre> Realiza 4 simulaciones del experimento de lanzar 10 veces la moneda, indicando el número de caras obtenidas en cada simulación.

Esperanza $E[X]$	$n \cdot p$		<pre>> (E=10*0.5) [1] 5</pre>
Varianza $Var[X]$	$n \cdot p \cdot (1-p)$		<pre>> (Var=10*0.5*(1-0.5)) [1] 2.5</pre>


Las funciones anteriores se pueden combinar con otras de generación de gráficos, para obtener los diagramas que se indican en la siguiente tabla.

Diagrama	Código R	Comentarios	Ejemplo de uso
Función de masa de probabilidad	<pre>plot(0:n, dbinom(0:n, n,p), type=tipo)</pre>	tipo puede ser: "l": líneas "h": barras "b": líneas y barras	<pre>>plot(0:10, dbinom(0:10, 10,0.5), type="h")</pre> 
Función de distribución acumulada	<pre>plot(0:n, pbinom(0:n, n,p), type="s")</pre> Otra opción: <pre>plot(stepfun(0:n-1, pbinom(0:n, n, p)))</pre>	type también puede ser: "l": líneas "h": barras "b": líneas y barras	<pre>>plot(0:10, pbinom(0:10, 10,0.5), type="s")</pre> 
Diagrama de frecuencias de una simulación de posibles valores de la variable aleatoria	<pre>plot(table(rbinom(m, n,p)), xlim=c(0,n))</pre>	En este caso se simulan los datos con la función rbinom. Se podría hacer lo mismo si se dispone de datos reales, para ver si las muestras reales tienen una distribución aproximadamente binomial. Por ejemplo, lanzando realmente una moneda.	<pre>>plot(table(rbinom(100, 10,0.5)), xlim=c(0,10))</pre> 

Se puede comparar el efecto en la función de masa de probabilidad al modificar los parámetros n y p , mostrando simultáneamente varios gráficos.

Por ejemplo, dividiendo la ventana gráfica en 2 filas y 3 columnas:

```
> par(mfrow=c(2,3))
> plot(0:10,dbinom(0:10,10,0.2), type="h", main = "B(10,0.2)")
> plot(0:10,dbinom(0:10,10,0.5), type="h", main = "B(10,0.5)")
> plot(0:10,dbinom(0:10,10,0.8), type="h", main = "B(10,0.8)")
> plot(0:50,dbinom(0:50,50,0.2), type="h", main = "B(50,0.2)")
> plot(0:50,dbinom(0:50,50,0.5), type="h", main = "B(50,0.5)")
> plot(0:50,dbinom(0:50,50,0.8), type="h", main = "B(50,0.8)")
> par(mfrow=c(1,1))
```



3. Variables discretas con distribución hipergeométrica

Una variable hipergeométrica es una variable discreta (X) que representa el número de éxitos (x) obtenidos en n ensayos (de Bernoulli), donde cada uno de ellos consiste en extraer un elemento de un conjunto inicial de N elementos, pero sin reposición, conociendo la probabilidad (p) del primer éxito, cuando están todos los elementos (N) en el conjunto.

Se trata de una variable similar a una variable binomial, pero en este caso los n ensayos no son independientes, porque no tienen la misma probabilidad de éxito cada uno de ellos, ya que en el primer ensayo en el conjunto hay N elementos, pero en el segundo ensayo ya no hay N sino $N-1$ elementos, y así sucesivamente hasta el ensayo n , en el que hay $N-n+1$ elementos.

Se representa como $X:H(N,n,p)$. Y se dice que la variable tiene una distribución hipergeométrica.


Por ejemplo, una variable $X:H(50,10,0.6)$ que representa: “Número de bolas blancas (éxitos) al sacar 10 bolas ($n=10$) sin reposición de una bolsa con 50 bolas, sabiendo que en la bolsa hay 30 bolas blancas ($p=30/50=0.6$) y 20 bolas negras”.

En R se pueden utilizar las funciones indicadas en la siguiente tabla. En la columna “Ejemplo de uso”, se utiliza una variable $H(50,10,0.6)$.

Función	Código R	Resultado	Ejemplo de uso
Masa de probabilidad $P\{X=x\}$	<code>dhyper(x, N*p, N*(1-p), n)</code>	Calcula la probabilidad de que una variable aleatoria hipergeométrica $X:H(N,n,p)$ tenga el valor x .	<pre>>dhyper(7, 30, 20, 10) [1] 0.2259296</pre>
Distribución acumulada $F(X)=P\{X\leq x\}$	<code>phyper(x, N*p, N*(1-p), n)</code>	Calcula la probabilidad de que una variable aleatoria hipergeométrica $X:H(N,n,p)$ tenga un valor igual o menor que x .	<pre>>phyper(7, 30, 20, 10) [1] 0.8609613</pre>
Cuantil	<code>qhyper(q, N*p, N*(1-p), n)</code>	Calcula el menor valor de una variable aleatoria hipergeométrica $X:H(N,n,p)$, que cumple que la probabilidad de que la variable sea menor o igual a ese valor, es mayor o igual a q .	<pre>>qhyper(0.4, 30, 20, 10) [1] 6</pre> Entonces se cumple: $P\{X\leq 6\} \geq 0.4$ Pero no se cumple: $P\{X\leq 5\} \geq 0.4$
Generación aleatoria de muestras	<code>rhyper(m, N*p, N*(1-p), n)</code>	Genera aleatoriamente un vector de m valores aleatorios de una	<pre>>rhyper(4, 30, 20, 10) [1] 5 6 6 4</pre>

Función	Código R	Resultado	Ejemplo de uso
		variable hipergeométrica $X:H(N,n,p)$. Cada valor representa el número de éxitos en cada simulación del experimento.	Realiza 4 simulaciones del experimento de sacar 10 bolas, indicando el número de bolas blancas (éxitos) obtenidas en cada simulación.
Esperanza $E[X]$	$n \cdot p$		<pre>> (E=10*0.6) [1] 6</pre>
Varianza $Var[X]$	$n \cdot p \cdot (1-p) \cdot (N-n) / (N-1)$		<pre>> (Var=10*0.6*0.4*(50-10)/(50-1)) [1] 1.959184</pre>

Los diagramas de las funciones anteriores son similares a los de la distribución binomial. En la siguiente tabla se muestra el diagrama de la función de masa de probabilidad.

Diagrama	Código R	Comentarios	Ejemplo de uso
Función de masa de probabilidad	<pre>plot(0:n,dhyper(0:n, N*p,N*(1-p),n), type=tipo)</pre>	tipo puede ser: "l": líneas "h": barras "b": líneas y barras	<pre>>plot(0:10,dhyper(0:10,30,20,10),type="h")</pre> 

3.1 Aproximación de una variable hipergeométrica a una binomial

Cuando el número de veces que se repite el experimento (n) de extraer un elemento de un conjunto es muy pequeño comparado con el número total de elementos del conjunto (N), la variable hipergeométrica se puede aproximar a una variable binomial, y se pueden usar las fórmulas de la binomial para el cálculo de probabilidades.

Por tanto, cuando N es mucho mayor¹ que n , una variable hipergeométrica $X: H(N, n, p)$ se puede aproximar a una variable binomial $X: B(n, p)$.

¹ No hay unanimidad respecto a lo que se entiende por mucho mayor. Algunos autores afirman que se puede realizar la aproximación cuando $N > 20 \cdot n$, y otros autores afirman que es suficiente que $N > 10 \cdot n$.

3.2 Ejemplo (aproximación binomial): Estudiantes que tienen móviles Android

ENUNCIADO

Mediante una encuesta, se sabe que 50 de 74 estudiantes de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá tienen teléfonos móviles con sistema operativo Android, y el resto con iOS. Si se pregunta aleatoriamente a 5 de los estudiantes, responder a las siguientes preguntas:

- a) Definir una variable aleatoria hipergeométrica para el experimento y aproximarla a una variable aleatoria binomial
- b) Calcular la esperanza y varianza de la variable aleatoria
- c) Dibujar las funciones de masa de probabilidad y distribución acumulada de la variable aleatoria
- d) Cuál es la probabilidad de que exactamente 3 de los 5 estudiantes tengan móvil con Android
- e) Cuál es la probabilidad de que 3 o menos de los 5 estudiantes tengan móvil con Android
- f) Cuál es la probabilidad de que tengan móvil con Android más de 3 de los 5 estudiantes
- g) Cuál es la probabilidad de que los 5 estudiantes tengan móvil con Android
- h) Cuál es la probabilidad de que ninguno de los 5 estudiantes tenga móvil con Android
- i) Cuál es la probabilidad de que 3 o 4 estudiantes tenga móvil con Android
- j) Cuál es el valor de los cuartiles de la variable aleatoria
- k) Si tenemos los datos de la encuesta original a los 74 alumnos, comprobar si tomando las respuestas en grupos de 5 alumnos, el diagrama de frecuencias se asemeja a la función de masa de probabilidad binomial.
- l) Repetir el apartado anterior, pero utilizando datos generados aleatoriamente con R, en lugar de los datos reales

SOLUCIÓN

a) Definir una variable aleatoria hipergeométrica para el experimento y aproximarla a una variable aleatoria binomial

X = Número de estudiantes que tienen móvil Android de una muestra de 5 estudiantes.

La variable sigue una distribución hipergeométrica, porque cuando se elige al primero de los 5 estudiantes de entre los 74 posibles, la probabilidad de que ese estudiante tenga Android viene dada por la proporción $p=50/74$; pero cuando se elige al siguiente esto ya no es así, porque la proporción de alumnos con Android ya no es la misma, ya que se ha eliminado al primer alumno del conjunto, y ahora el conjunto es de 73 alumnos. Y así sucesivamente.

Sería una variable $X:H(N,n,p)$, donde $N=74$, $n=5$ y $p=50/74$.

El valor p es $50/74$ ya que por las encuestas se sabe que 50 de los 74 alumnos tienen móvil Android, como puede comprobarse leyendo los datos del archivo [encuesta.csv](#) y generando una tabla de frecuencias absolutas.

```
> encuesta=read.csv2("encuesta.csv")
> encuesta$SO
[1] "Android" "iOS"      "Android" "iOS"      "Android" "Android" "Android" "Android" "iOS"      "iOS"
[11] "iOS"      "Android" "Android" "iOS"      "Android" "iOS"      "Android" "iOS"      "Android" "Android"
[21] "Android" "iOS"      "Android" "iOS"      "Android" "iOS"      "Android" "Android" "Android" "iOS"
[31] "Android" "Android" "iOS"      "Android" "Android" "iOS"      "Android" "Android" "Android" "Android"
[41] "iOS"      "Android" "Android" "Android" "Android" "Android" "iOS"      "Android" "Android" "Android"
[51] "iOS"      "iOS"      "iOS"      "Android" "Android" "iOS"      "iOS"      "Android" "iOS"      "Android"
[61] "Android" "iOS"      "Android" "iOS"      "Android" "Android" "Android" "Android" "Android" "Android"
[71] "Android" "Android" "Android" "Android"
```

```
> table(encuesta$SO)
Android      iOS
        50         24
```

Como $N=74$ es mucho mayor² que el tamaño de la muestra $n=5$, se puede realizar una aproximación a una variable binomial.

Por tanto, la variable binomial equivalente sería $X:B(n,p)$, donde $n=5$ y $p=50/74$.

Empezamos dando valores a los parámetros n y p . Por simplicidad vamos a redondear todos los valores con dos cifras decimales.

```
> (n=5)
[1] 5
> (p=round(50/74,2))
[1] 0.68
```


b) Calcular la esperanza y varianza de la variable aleatoria

```
> (Esperanza = round(n*p,2))
[1] 3.4
> (Varianza = round(n*p*(1-p),2))
[1] 1.09
```

c) Dibujar las funciones de masa de probabilidad y distribución acumulada.

```
> par(mfrow=c(1,2))
> plot(0:n,dbinom(0:n,n,p),type="h",main="Función de masa de probabilidad")
> plot(0:n,pbinom(0:n,n,p),type="s",main="Función de distribución acumulada")
> par(mfrow=c(1,1))
```

² No hay unanimidad respecto a lo que se entiende por “mucho mayor”. [Unos autores](#) afirman que la aproximación es “buena” si $N > 20 \cdot n$; [otros autores](#) afirman que es suficiente que $N > 10 \cdot n$. Se ha seguido la recomendación de los autores que indican que la aproximación puede realizarse cuando $N > 10 \cdot n$, ya que en este caso $N=74$ y $n=5$, por lo que se cumple que $74 > 50$.



d) Cuál es la probabilidad de que exactamente 3 de los 5 estudiantes tengan móvil con Android

Se trata de calcular $P\{X=3\}$, usando la función de masa de probabilidad `dbinom()`:

```
> round(dbinom(3,n,p),2)
[1] 0.3
```

e) Cuál es la probabilidad de que 3 o menos de los 5 estudiantes tengan móvil con Android

Se trata de calcular $P\{X \leq 3\}$. Se puede usar, por tanto la función de distribución acumulada `pbinom()`:

```
> round(pbinom(3,n,p),2)
[1] 0.51
```

También se podría calcular como $P\{X \leq 3\} = P\{X=0\} + P\{X=1\} + P\{X=2\} + P\{X=3\}$, es decir usando la función de masa de probabilidad en lugar de la de distribución acumulada:

```
> round(dbinom(0,n,p)+dbinom(1,n,p)+dbinom(2,n,p)+dbinom(3,n,p),2)
[1] 0.51
```

f) Cuál es la probabilidad de que tengan móvil con Android más de 3 de los 5 estudiantes

Como ya sabemos calcular $P\{X \leq 5\}$, se puede resolver como $P\{X > 3\} = 1 - P\{X \leq 3\}$:

```
> 1-round(pbinom(3,n,p),2)
[1] 0.49
```

También se podría calcular como $P\{X>3\}=P\{X=4\}+P\{X=5\}$:

```
> round(dbinom(4,n,p)+dbinom(5,n,p),2)
[1] 0.49
```

g) Cuál es la probabilidad de que los 5 estudiantes tengan móvil con Android

```
> round(dbinom(5,n,p),2)
[1] 0.15
```

h) Cuál es la probabilidad de que ninguno de los 5 estudiantes tenga móvil con Android

```
> dbinom(0,n,p)
[1] 0.003355443
```

i) Cuál es la probabilidad de que entre 3 y 4 estudiantes tengan móvil con Android

Se trata de calcular $P\{X=3\}+P\{X=4\}$:

```
> round(dbinom(3,n,p)+dbinom(4,n,p),2)
[1] 0.66
```

También se puede calcular como $P\{X\leq 4\}-P\{X\leq 2\}$, es decir usando la función de distribución acumulada en lugar de la de masa de probabilidad:

```
> round(pbinom(4,n,p)-pbinom(2,n,p),2)
[1] 0.66
```

j) Cuál es el valor de los cuantiles de la variable aleatoria (es decir los percentiles 25%, 50%, 75%, 100%, o cuantiles 0.25, 0.50, 0.75, 1)

En lugar de ejecutar 4 veces la función `qbinom()`, una para cada cuartil, se puede pasar como primer argumento, un vector con los valores de los cuantiles correspondientes a cada cuartil:

```
> qbinom(c(0.25,0.50,0.75,1),n,p)
[1] 3 3 4 5
```

Lo que indican estos resultados es que:

- $P\{X\leq 3\} \geq 0.25$
- $P\{X\leq 3\} \geq 0.50$
- $P\{X\leq 4\} \geq 0.75$
- $P\{X\leq 5\} = 1$

Puede comprobarse que es cierto con la función de distribución acumulada, viendo el diagrama de esta función en el apartado c) o calculando los valores con `pbinom()`. Por ejemplo, en el caso del cuartil 0.25, no puede ser el valor 2, porque $P\{X \leq 2\}$ es 0.19 y por tanto no llega a 0.25.

```
> round(pbinom(2,n,p),2)
[1] 0.19
> round(pbinom(3,n,p),2)
[1] 0.51
```

k) Si tenemos los datos de la encuesta original a los 74 estudiantes, comprobar si tomando las respuestas de la encuesta en grupos de 5 estudiantes, el histograma se ajusta realmente a la función de masa de probabilidad binomial.


Las respuestas sobre el sistema operativo que utilizaban los estudiantes fueron:

```
> so
[1] "Android" "iOS"      "Android" "iOS"      "Android"
[6] "Android" "Android" "Android" "iOS"      "iOS"
[11] "iOS"      "Android" "Android" "iOS"      "Android"
[16] "iOS"      "Android" "iOS"      "Android" "Android"
[21] "Android" "iOS"      "Android" "iOS"      "Android"
[26] "iOS"      "Android" "Android" "Android" "iOS"
[31] "Android" "Android" "iOS"      "Android" "Android"
[36] "iOS"      "Android" "Android" "Android" "Android"
[41] "iOS"      "Android" "Android" "Android" "Android"
[46] "Android" "iOS"      "Android" "Android" "Android"
[51] "iOS"      "iOS"      "iOS"      "Android" "Android"
[56] "iOS"      "iOS"      "Android" "iOS"      "Android"
[61] "Android" "iOS"      "Android" "iOS"      "Android"
[66] "Android" "Android" "Android" "Android" "Android"
[71] "Android" "Android" "Android" "Android"
```

Al aparecer los resultados en bloques de 5 estudiantes, podemos contar las veces que aparece "Android" en cada uno de los 7 bloques de 5 estudiantes, y se obtiene: 3, 3, 3, 3, 3, 3, 4, 4, 4, 4, 2, 2, 3, 5.

Podemos crear un vector con esos valores y dibujar un diagrama con sus frecuencias y comprobar si se parece a la función de masa de probabilidad de una distribución Binomial.

```
> (android = c(3, 3, 3, 3, 3, 3, 4, 4, 4, 4, 2, 2, 3, 5))
[1] 3 3 3 3 3 3 4 4 4 4 2 2 3 5
> par(mfrow=c(1,2))
> plot(table(android), xlim=c(0,n), main="Frecuencias de la muestra")
> plot(0:n,dbinom(0:n,n,p),type="h", main="Masa de probabilidad Binomial")
```




Puede comprobarse visualmente que el diagrama de frecuencias de los datos reales de la muestra se asemeja a la forma de la distribución binomial usada en este ejemplo.

I) Repetir el apartado anterior, pero utilizando datos generados aleatoriamente con R, en lugar de los datos reales

Repetimos los comandos del apartado anterior, pero en este caso generamos aleatoriamente una muestra con los resultados de repetir 7 veces el experimento con los mismos valores de n y p que en el caso anterior, pero ahora utilizando la función `rbinom()`.

```
> (muestra=rbinom(7,n,p))
[1] 4 3 3 3 4 5 2
> par(mfrow=c(1,2))
> plot(table(muestra), xlim=c(0,n),main="Frecuencias de la muestra")
> plot(0:n,dbinom(0:n,n,p),type="h", main="Masa de probabilidad Binomial")
```



Si se ejecuta la función `rbinom()` varias veces, en cada ocasión se obtendrá valores diferentes, pero en general puede comprobarse que se asemejan a la distribución binomial.

4. Variables discretas con distribución de Poisson

Una variable aleatoria que tiene una distribución de Poisson es una variable discreta (X) que representa el número de eventos “raros” que ocurren en un determinado periodo de tiempo conociendo la frecuencia o número medio de esos sucesos que ocurren por unidad de tiempo (λ)³. Se representa como $X:P(\lambda)$.




Por ejemplo, una variable $X:P(10)$ que representa: “Número de visitas a un sitio web, sabiendo que la media de visitas en una hora es de 10 ($\lambda=10$)”.

En R se pueden utilizar las funciones indicadas en la siguiente tabla. En la columna “Ejemplo de uso”, se utiliza una variable $P(10)$.

Función	Código R	Resultado	Ejemplo de uso
Masa de probabilidad $P\{X=x\}$	<code>dpois(x, λ)</code>	Calcula la probabilidad de que una variable aleatoria de Poisson $X:P(\lambda)$ tenga el valor x .	<pre>> dpois(15,10) [1] 0.03471807</pre>
Distribución acumulada $F(X)=P\{X\leq x\}$	<code>ppois(x, λ)</code>	Calcula la probabilidad de que una variable aleatoria de Poisson $X:P(\lambda)$ tenga un valor igual o menor que x .	<pre>> ppois(15,10) [1] 0.9512596</pre>
Cuantil	<code>qpois(q, λ)</code>	Calcula el menor valor de una variable aleatoria de Poisson $X:P(\lambda)$ que cumple que la probabilidad de que la variable sea menor o igual a ese valor es mayor o igual a q .	<pre>> qpois(0.7,10) [1] 12</pre> Entonces se cumple: $P\{X\leq 12\} \geq 0.7$ Pero no se cumple: $P\{X\leq 11\} \geq 0.7$
Generación aleatoria de muestras	<code>rpois(m, λ)</code>	Genera aleatoriamente un vector de m valores aleatorios de una variable de Poisson $X:P(\lambda)$.	<pre>> rpois(4,10) [1] 7 9 8 16</pre>
Esperanza $E[X]$	λ		<pre>> (E=10) [1] 10</pre>
Varianza $Var[X]$	λ		<pre>> (Var=10) [1] 10</pre>

³ El símbolo λ (letra griega lambda) se escribe pulsando Alt + 955.


Las funciones anteriores se pueden combinar con otras de generación de gráficos, para obtener los diagramas que se indican en la siguiente tabla.

Diagrama	Código R	Comentarios	Ejemplo de uso
Función de masa de probabilidad	<code>plot(0:n,dpois(0:n,λ),type=tipo)</code>	tipo puede ser: "l": líneas "h": barras "b": líneas y barras	<pre>>plot(0:40,dpois(0:40,10),type="h")</pre> 
Función de distribución acumulada	<code>plot(0:n,ppois(0:n,λ),type="s")</code>	type también puede ser: "l": líneas "h": barras "b": líneas y barras	<pre>>plot(0:40,ppois(0:40,10),type="s")</pre> 
Diagrama de frecuencias de una simulación de posibles valores de la variable aleatoria	<code>plot(table(rpois(m,λ)),xlim=c(0,m))</code>	En este caso se simulan los datos con la función rpois. Se podría hacer lo mismo si se dispone de datos reales, para ver si las muestras reales tienen una distribución aproximadamente de Poisson.	<pre>>plot(table(rpois(40,10)),xlim=c(0,40))</pre> 

Se puede comparar el efecto de modificar el parámetro λ en la función de masa de probabilidad, mostrando simultáneamente varios gráficos.

Por ejemplo, dividiendo la ventana gráfica en 3 columnas:

```
> par(mfrow=c(1,3))  
> plot(0:40,dpois(0:40,10), type="h", main = "\lambda=10")  
> plot(0:40,dpois(0:40,20), type="h", main = "\lambda=20")  
> plot(0:40,dpois(0:40,30), type="h", main = "\lambda=30")  
> par(mfrow=c(1,1))
```



4.1 Ejemplo: Correo electrónico no deseado (spam)

ENUNCIADO

Una persona ha comprobado que recibe una media de 5 mensajes al día de correo electrónico no deseado (spam).

- Definir una variable aleatoria de Poisson para el número de mensajes no deseados recibidos en una semana (7 días)
- Calcular la esperanza y varianza de la variable aleatoria
- Dibujar las funciones de masa de probabilidad y distribución acumulada de la variable aleatoria
- Cuál es la probabilidad de que se reciban 20 mensajes no deseados en una semana
- Cuál es la probabilidad de que se reciban 20 o menos mensajes no deseados en una semana
- Cuál es la probabilidad de que se reciban más de 20 mensajes no deseados en una semana
- Cuál es la probabilidad de que no se reciba ningún mensaje en una semana
- Cuál es la probabilidad de que se reciban entre 20 y 30 mensajes no deseados en una semana
- Cuál es el valor de los cuartiles de la variable aleatoria
- Generar aleatoriamente 100 valores para la variable y comprobar si el diagrama de frecuencias se asemeja a la función de masa de probabilidad de Poisson.
- Definir una nueva variable aleatoria para calcular la probabilidad de que en un día se reciban 3 mensajes.
- Generar aleatoriamente 100 valores para la nueva variable y comprobar si el diagrama de frecuencias se asemeja a la función de masa de probabilidad de Poisson.

SOLUCIÓN

a) Definir una variable aleatoria de Poisson para el número de mensajes no deseados recibidos en una semana (7 días)

X = Mensajes no deseados recibidos en una semana, sabiendo que la media de mensajes no deseados recibidos en un día es de 5 mensajes.

La variable sigue una distribución de Poisson $P(\lambda)$, donde $\lambda=5*7=35$ mensajes/semana. Por simplicidad se utiliza "lambda" en lugar de " λ " en el código R.

```
> (lambda=35)
[1] 35
```

b) Calcular la esperanza y varianza de la variable aleatoria


La esperanza y varianza coinciden con λ , por lo que su valor es 35.

```
> (Esperanza = lambda)
```

```
[1] 35
> (Varianza = lambda)
[1] 35
```

c) Dibujar las funciones de masa de probabilidad y distribución acumulada de la variable aleatoria

```
> par(mfrow=c(1,2))
> plot(0:100,dpois(0:100,lambda),type="h",main="Función de masa de probabilidad")
> plot(0:100,ppois(0:100,lambda),type="s",main="Función de distribución acumulada")
> par(mfrow=c(1,1))
```



d) Cuál es la probabilidad de que se reciban 20 mensajes no deseados en una semana

Se trata de calcular $P\{X=20\}$, usando la función de masa de probabilidad `dpois()`:

```
> dpois(20,lambda)
[1] 0.001972102
```

e) Cuál es la probabilidad de que se reciban 20 o menos mensajes no deseados en una semana

Se trata de calcular $P\{X \leq 20\}$. Se puede usar, por tanto la función de distribución acumulada `ppois()`:

```
> ppois(20,lambda)
[1] 0.004296609
```

f)Cuál es la probabilidad de que se reciban más de 20 mensajes no deseados en una semana

Como ya sabemos $P\{X \leq 20\}$, se puede calcular como $P\{X > 20\} = 1 - P\{X \leq 20\}$:

```
> 1-ppois(20,lambda)
[1] 0.9957034
```

g)Cuál es la probabilidad de que no se reciba ningún mensaje en una semana

```
> dpois(0,lambda)
[1] 6.305117e-16
```

Para que el resultado no se obtenga con notación científica, puede cambiarse la opción `scipen` antes de ejecutar el cálculo. Para volver a la notación científica puede ejecutarse `options(scipen=0)`.

```
> options(scipen = 100)
> dpois(0,lambda)
[1] 0.0000000000000006305117
```

h)Cuál es la probabilidad de que se reciban entre 20 y 30 mensajes no deseados en una semana

Se trata de calcular $P\{X=20\}+P\{X=21\}+\dots+P\{X=30\}$, pero es más fácil calcularlo como $P\{X \leq 30\} - P\{X \leq 20\}$, usando la función de distribución acumulada en lugar de la de masa de probabilidad:

```
> ppois(30,lambda)-ppois(19,lambda)
[1] 0.2246179
```

i)Cuál es el valor de los cuartiles de la variable aleatoria (es decir los percentiles 25%, 50%, 75%, 100%, o cuantiles 0.25, 0.50, 0.75, 1)

En lugar de ejecutar 4 veces la función `qpois()`, una para cada cuartil, se puede pasar como primer argumento, un vector con los valores de los cuantiles correspondientes a cada cuartil:

```
> qpois(c(0.25,0.50,0.75,1),lambda)
[1] 31 35 39 Inf
```

Lo que indican estos resultados es que:

- $P\{X \leq 31\} \geq 0.25$
- $P\{X \leq 35\} \geq 0.50$
- $P\{X \leq 39\} \geq 0.75$
- $P\{X \leq \text{Infinito}\} = 1$


Puede comprobarse que es cierto con la función de distribución acumulada, viendo el diagrama de esta función en el apartado c) o calculando los valores con `ppois()`. Por ejemplo en el caso del cuantil 0.25, no puede ser el valor 30, porque $P\{X \leq 30\}$ es 0.23 y por tanto no llega a 0.25.

```
> round(ppois(30,lambda),2)
[1] 0.23
> round(ppois(31,lambda),2)
[1] 0.28
```


j) Generar aleatoriamente 100 valores para la variable y comprobar si el diagrama de frecuencias se asemeja a la función de masa de probabilidad de Poisson.

```
> (muestra=rpois(100,lambda))
[1] 34 33 37 34 31 38 27 37 34 44 45 45 40 38 35 40 34 30 34 32 45 31
[23] 39 37 45 36 29 32 32 40 27 29 31 35 30 26 31 42 41 35 44 32 36 32
[45] 26 35 35 33 32 33 44 33 33 35 25 40 28 37 32 46 32 28 39 32 36 34
[67] 27 34 27 32 27 40 31 31 31 31 30 36 36 32 37 38 36 36 32 39 38 25
[89] 34 27 38 35 38 38 23 39 27 22 39 40
> par(mfrow=c(1,2))
> plot(table(muestra), xlim=c(0,100), main="Frecuencias de la muestra")
> plot(0:100,dpois(0:100,lambda), type="h", main="Masa de probabilidad de Poisson")
```

Frecuencias de la muestra



Masa de probabilidad de Poisson



Si se ejecuta la función `rpois()` varias veces, en cada ocasión se obtendrán valores diferentes, pero en general puede comprobarse que se ajustan a la distribución de Poisson.

k) Definir una nueva variable aleatoria para calcular la probabilidad de que en un día se reciban 3 mensajes.

En este caso, la nueva variable sería “Mensajes no deseados recibidos en un día, sabiendo que la media de mensajes no deseados recibidos en un día es de 5 mensajes”, y el parámetro λ de la variable sería 5.


```
> dpois(3,5)
[1] 0.1403739
```

l) Generar aleatoriamente 100 valores para la nueva variable y comprobar si el histograma se ajusta realmente a la función de masa de probabilidad de Poisson.


```
> (muestra=rpois(100,5))
[1] 2 5 4 6 5 7 4 4 5 5 2 3 5 3 6 7 4 3 5 2 1 6
[23] 6 4 2 6 4 5 8 5 3 4 7 8 6 6 6 7 9 0 7 8 5 10
[45] 4 4 6 7 5 7 7 9 5 2 4 7 5 4 7 9 5 5 6 0 5 5
[67] 2 3 5 6 0 1 6 8 5 4 4 2 11 4 3 4 5 5 4 4 7 2
[89] 6 6 5 3 5 5 4 7 3 14 7 6

> par(mfrow=c(1,2))
> plot(table(muestra), xlim=c(0,20),main="Frecuencias de la muestra")
> plot(0:100,dpois(0:100,5),xlim=c(0,20),type="h", main="Masa de probabilidad de Poisson")
```

Frecuencias de la muestra



Masa de probabilidad de Poisson



4.2 Aproximar una variable binomial a una distribución de Poisson


Si en una variable binomial $B(n,p)$ se cumple que n es grande y p pequeño⁴, entonces se puede aproximar a una distribución de Poisson $P(\lambda)$ con $\lambda=n \cdot p$.

Se puede comprobar por ejemplo con $B(100,0.05)$, aproximándola a una de Poisson con $\lambda=100 \cdot 0.05=5$.

```
> dbinom(2,100,0.05)
[1] 0.08118177
> dpois(2,5)
[1] 0.08422434
```

Podemos comparar gráficamente sus funciones de masa de probabilidad:

```
> par(mfrow=c(1,2))
> plot(0:20,dbinom(0:20,100,0.05),type="h",main="Binomial")
> plot(0:20,dpois(0:20,5),type="h",main="Poisson")
> par(mfrow=c(1,1))
```



⁴ No hay unanimidad respecto a lo que se entiende por “grande” y “pequeño”. Algunos autores afirman que la aproximación es “buena” si $n \geq 20$ y $p \leq 0,05$ y “muy buena” si $n \geq 100$ y $p \leq 0,01$, otros que se cumpla $n \geq 30$ y $np < 10$ o $n(1-p) < 10$, otros que $n > 30$ y $p < 0.1$, otros que es suficiente que $np < 5$, otros que $np > 1$ y $p < 0.1$, etc.

5. Otras distribuciones discretas

En R se pueden utilizar otras distribuciones de probabilidad para variables aleatorias discretas, y para todas ellas existen las funciones de masa de probabilidad, de distribución acumulada, de cálculo de cuantiles y de generación de valores aleatorios. Se trata de las siguientes:

Distribución	Función de masa de probabilidad	Función de distribución acumulada	Cuantiles	Generación valores aleatorios
Binomial negativa	<code>dnbinom()</code>	<code>pnbinom()</code>	<code>qnbinom()</code>	<code>rnbinom()</code>
Geométrica	<code>dgeom()</code>	<code>pgeom()</code>	<code>qgeom()</code>	<code>rgeom()</code>
Multinomial	<code>dmultinom()</code>	<code>pmultinom()</code>	<code>qmultinom()</code>	<code>rmultinom()</code>

Para ver la ayuda sobre todas las distribuciones en R se debe ejecutar el comando `help("Distributions")`.

Se pueden encontrar ejemplos en R en <https://fhernanb.github.io/Manual-de-R/discretas.html>. Y los fundamentos teóricos de éstas y otras distribuciones de variables discretas en https://es.m.wikipedia.org/wiki/Distribución_de_probabilidad.

6. Ejercicios propuestos

- 1) Si se lanza 50 veces un dado de seis lados con valores 1, 2, 3, 4, 5 y 6 en cada lado:
 - a. Definir una variable aleatoria binomial para el experimento
 - b. Calcular la esperanza y varianza de la variable aleatoria
 - c. Dibujar las funciones de masa de probabilidad y distribución acumulada de la variable aleatoria
 - d. Calcular la probabilidad de que nunca aparezca el lado con el valor 6.
 - e. Calcular la probabilidad de que siempre aparezca el lado con el valor 6.
 - f. Calcular la probabilidad de que el lado con el valor 6 aparezca menos de 10 veces.
 - g. Calcular la probabilidad de que el lado con el valor 6 aparezca más de 10 veces.
 - h. Calcular la probabilidad de que el lado con el valor 6 aparezca entre 20 y 40 veces.
 - i. Calcular los cuantiles 50 y 90.
 - j. Generar aleatoriamente 100 valores para la variable y comprobar si el diagrama de frecuencias se asemeja a la función de masa de probabilidad Binomial.

- 2) Mediante una encuesta cuyas respuestas están disponibles en el archivo encuesta.csv, se sabe que 26 de 74 estudiantes de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá tienen una línea telefónica contratada con las compañías Jazzte/Orange/Simyo. Si se pregunta aleatoriamente a 6 de los estudiantes, responder a las siguientes preguntas:
 - a. Definir una variable aleatoria hipergeométrica para el experimento y aproximarla a una variable binomial
 - b. Calcular la esperanza y varianza de la variable aleatoria
 - c. Dibujar las funciones de masa de probabilidad y distribución acumulada de la variable aleatoria
 - d. Cuál es la probabilidad de que exactamente 3 de los 6 estudiantes tengan contrato con Jazzte/Orange/Simyo
 - e. Cuál es la probabilidad de que 3 o menos de los 6 estudiantes tengan contrato con Jazzte/Orange/Simyo
 - f. Cuál es la probabilidad de que tengan contrato con Jazzte/Orange/Simyo más de 3 de los 6 estudiantes
 - g. Cuál es la probabilidad de que los 6 estudiantes tengan contrato con Jazzte/Orange/Simyo
 - h. Cuál es la probabilidad de que ninguno de los 6 estudiantes tenga contrato con Jazzte/Orange/Simyo
 - i. Cuál es la probabilidad de que entre 2 y 4 estudiantes tengan contrato con Jazzte/Orange/Simyo
 - j. Cuál es el valor de los cuantiles de la variable aleatoria
 - k. Si tenemos los datos de la encuesta original a los 74 alumnos, comprobar si tomando las respuestas en grupos de 6 alumnos, el diagrama de frecuencias se asemeja a la función de masa de probabilidad binomial.

- l. Repetir el apartado anterior, pero utilizando datos generados aleatoriamente con R, en lugar de los datos reales
- 3) Se ha comprobado que un sitio web tiene una media de 120 visitas al día.
- a. Definir una variable aleatoria de Poisson para el número de visitas en una hora
 - b. Calcular la esperanza y varianza de la variable aleatoria
 - c. Dibujar las funciones de masa de probabilidad y distribución acumulada de la variable aleatoria
 - d. Cuál es la probabilidad de que haya 4 visitas en una hora
 - e. Cuál es la probabilidad de que haya 4 o menos visitas en una hora
 - f. Cuál es la probabilidad de que haya más de 4 visitas en una hora
 - g. Cuál es la probabilidad de que no haya ninguna visita en una hora
 - h. Cuál es la probabilidad de que haya entre 4 y 6 visitas en una hora
 - i. Cuál es el valor de los cuartiles de la variable aleatoria
 - j. Generar aleatoriamente 100 valores para la variable y comprobar si el diagrama de frecuencias se asemeja a la función de masa de probabilidad de Poisson.
 - k. Definir una nueva variable aleatoria para calcular la probabilidad de que en un día haya 100 visitas.
 - l. Generar aleatoriamente 100 valores para la nueva variable y comprobar si diagrama de frecuencias se asemeja a la función de masa de probabilidad de Poisson.