

Estadística

Práctica 7

Intervalos de confianza para parámetros

Contenido

1. Introducción.....	3
1.1 Comprobación de normalidad en muestras pequeñas	7
1.1.1 Ejemplo de comprobación de normalidad de una muestra pequeña de notas	9
2. Ejemplo: Intervalo de confianza para la media de calificaciones de estudiantes (muestra grande)	14
3. Ejemplo: Intervalo de confianza para la media de calificaciones de estudiantes (muestra pequeña) .	19
4. Ejemplo: Intervalo de confianza para las proporción de estudiantes que tienen móvil Android.....	22
5. Ejercicios propuestos	26
ANEXO. Transformación de datos para conseguir Normalidad	27
1) Transformación logarítmica	27
2) Transformación Box-Cox	29

1. Introducción

Con esta práctica se utiliza R y RStudio para estimar (inferir), con un nivel de confianza determinado, el intervalo en el que se encuentra el valor de los parámetros de una población (media, varianza y proporción) a partir de una muestra de la misma.

En estadística hay que diferenciar entre los conceptos “parámetro” y “estadístico”. El término “parámetro” suele utilizarse en referencia a una población mientras que el término “estadístico” suele utilizarse en referencia a una muestra extraída de dicha población. En la siguiente tabla se muestra la nomenclatura utilizada habitualmente.

PARÁMETROS (POBLACIONALES)	ESTADÍSTICOS (MUESTRALES)
Media poblacional (μ)	Media muestral ($\bar{x}$)
Desviación estándar poblacional (σ)	Desviación estándar muestral (s)
Varianza poblacional (σ^2)	Varianza muestral (s^2)
Tamaño población (N)	Tamaño muestra (n)
Proporción poblacional (p)	Proporción muestral ($\hat{p}$)

Se puede calcular el intervalo en el que se puede asegurar que se encuentra el valor de un parámetro poblacional con un determinado nivel de confianza, obteniendo lo que se conoce como Intervalo de Confianza, con un límite inferior L_i y un límite superior L_s :

$$\text{Intervalo de confianza con nivel de confianza } 1 - \alpha = [L_i, L_s]$$

El nivel de confianza ($1 - \alpha$) es un valor de 0 a 1, y representa la probabilidad de acertar en la predicción, es decir la probabilidad de que el valor real del parámetro se encuentre entre los límites del intervalo. Se suele utilizar en % multiplicando por 100. En la expresión del nivel de confianza aparece un valor α (alfa) que se denomina nivel de error o nivel de significación, y representa lo contrario que la confianza, es decir, la probabilidad de no acertar en la predicción.

En la siguiente tabla se indican las fórmulas para calcular los parámetros poblacionales y su posible programación utilizando el lenguaje R.

Parámetro a calcular	Se conoce la varianza poblacional (σ^2)	Intervalo de confianza (Li, Ls)	Código R
Media poblacional (μ)	Si	$Li = \bar{x} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$ $Ls = \bar{x} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$	n=tamaño muestra z=qnorm(1-alfa/2,0,1) m=media muestral sigma=desviación poblacional Li=m-z*(sigma/sqrt(n)) Ls=m+z*(sigma/sqrt(n))
		OTRA FORMA El estimador $\bar{X}$ es una variable aleatoria $Normal\left(\bar{x}, \frac{\sigma}{\sqrt{n}}\right)$ por lo que: $Li = \text{cuantil}(\alpha/2) \text{ de } \bar{X}$ $Ls = \text{cuantil}(1 - \alpha/2) \text{ de } \bar{X}$	Li=qnorm(alfa/2, m, sigma/sqrt(n)) Ls=qnorm(1-alfa/2, m, sigma/sqrt(n))
	No $n \geq 30$	$Li = \bar{x} - z_{\frac{\alpha}{2}} \frac{s}{\sqrt{n}}$ $Ls = \bar{x} + z_{\frac{\alpha}{2}} \frac{s}{\sqrt{n}}$	n=tamaño muestra z=qnorm(1-alfa/2,0,1) m=media muestral s=desviación muestral Li=m-z*(s/sqrt(n)) Ls=m+z*(s/sqrt(n))
		OTRA FORMA El estimador $\bar{X}$ es una variable aleatoria $Normal\left(\bar{x}, \frac{s}{\sqrt{n}}\right)$ por lo que: $Li = \text{cuantil}(\alpha/2) \text{ de } \bar{X}$ $Ls = \text{cuantil}(1 - \alpha/2) \text{ de } \bar{X}$	Li=qnorm(alfa/2, m, s/sqrt(n)) Ls=qnorm(1-alfa/2, m, s/sqrt(n))
	No $n < 30$ Distribución Normal	$Li = \bar{x} - t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}}$ $Ls = \bar{x} + t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}}$	n=tamaño muestra t=qt(1-alfa/2,n-1) m=media muestral s=desviación muestral Li=m-t*(s/sqrt(n)) Ls=m+t*(s/sqrt(n))
		$Li = \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}, n-1}^2}$ $Ls = \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2}$	n=tamaño muestra chi.li=qchisq(1-alfa/2,n-1) chi.ls=qchisq(alfa/2,n-1) s=desviación muestral Li=((n-1)*s^2)/chi.li Ls=((n-1)*s^2)/chi.ls
Varianza poblacional (σ^2)	No Distribución Normal	$Li = \frac{(n-1)s^2}{\chi_{\frac{\alpha}{2}, n-1}^2}$ $Ls = \frac{(n-1)s^2}{\chi_{1-\frac{\alpha}{2}, n-1}^2}$	n=tamaño muestra chi.li=qchisq(1-alfa/2,n-1) chi.ls=qchisq(alfa/2,n-1) s=desviación muestral Li=((n-1)*s^2)/chi.li Ls=((n-1)*s^2)/chi.ls

Parámetro a calcular	Se conoce la varianza poblacional (σ^2)	Intervalo de confianza (Li, Ls)	Código R
Proporción poblacional ¹ (p)	--- $n \geq 30$	$L_i = \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ $L_s = \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	n =tamaño muestra z = <code>qnorm(1-alfa/2,0,1)</code> p =proporción $Li=p-z*\sqrt{p*(1-p)/n}$ $Li=p+z*\sqrt{p*(1-p)/n}$
		OTRA FORMA El estimador $\hat{P}$ es una variable aleatoria $Normal\left(\hat{p}, \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right)$ por lo que: $Li = \text{cuantil}(\alpha/2) \text{ de } \hat{P}$ $Ls = \text{cuantil}(1 - \alpha/2) \text{ de } \hat{P}$	Li = <code>qnorm(alfa/2, p, sqrt(p*(1-p)/n))</code> Ls = <code>qnorm(1-alfa/2, p, sqrt(p*(1-p)/n))</code>

Existen en R funciones que se pueden utilizar para los cálculos de algunos intervalos sin tener que programar las fórmulas de la tabla anterior. Son la función predefinida `t.test()`, y las funciones `z.test()` del paquete `BSDA`, y `binom.confint()` del paquete `binom`, que se pueden utilizar como se indica en la siguiente tabla.

¹ Sólo se considera el caso de muestras grandes. Existen métodos para el cálculo de intervalos de confianza para proporciones a partir de muestras pequeñas (<30), por ejemplo, el método de Wilson: <https://problabtools.com/intervalo-confianza-proporcion.html>

Parámetro a calcular	Código R	Ejemplo
Media poblacional – muestra grande (μ)	<pre>install.packages("BSDA") library(BSDA) test= z.test(muestra, mu=media muestral, sigma.x=desviación típica muestral, conf.level = 0.95) Intervalo: test\$conf.int</pre>	<pre>> muestra=rnorm(50,5,1) > prueba=z.test(muestra, mu=5, sigma.x=1, conf.level=0.95) > prueba\$conf.int [1] 4.713116 5.267477</pre>
Media poblacional – muestra pequeña (μ)	<pre>test=t.test(muestra, conf.level = 0.95) Intervalo: test\$conf.int</pre>	<pre>> muestra=c(5,5,4,6,4,5,5,3,3,6) > prueba=t.test(muestra, conf.level = 0.95) > prueba\$conf.int [1] 3.831014 5.368986</pre>
Proporción poblacional – muestra grande (p)	<pre>Intervalo: install.packages("binom") library(binom) binom.confint(ng, n, conf.level = 1-alfa, methods = "asymptotic")² NOTA: n es el tamaño de la muestra. ng es el tamaño del grupo de datos de la muestra para el que se calcula la proporción, es decir la proporción muestral p sería ng/n.</pre>	<pre>> binom.confint(70, 100, conf.level = 0.95, methods = "asymptotic") lower upper 0.6101832 0.7898168</pre>

² No existe unanimidad sobre el método de cálculo del intervalo de confianza para proporciones.

<https://stats.stackexchange.com/questions/207807/95-confidence-interval-for-proportions-in-r>

La función `binom.confint` permite aplicar nueve métodos diferentes. Si se indica el método "asymptotic", se aplican las fórmulas de la tabla.

1.1 Comprobación de normalidad en muestras pequeñas




Para poder aplicar los métodos de cálculo de los intervalos de confianza indicados en el apartado anterior, se necesita que los datos provengan de una población con una distribución de datos (o frecuencia de datos) que se aproxime a una distribución Normal; o al menos que las medias de las posibles muestras de un mismo tamaño que puedan extraerse de dicha población tengan una distribución Normal.

Cuando la muestra disponible es grande ($n \geq 30$), en virtud del Teorema Central del Límite, se asume que la variable aleatoria que representa la media de cada una posible muestra de tamaño n que se podría elegir aleatoriamente de la población, tiene una distribución Normal, por lo que no hay que realizar ninguna comprobación de normalidad.

Pero en el caso de que la muestra sea pequeña ($n < 30$), no se puede aplicar el Teorema Central del Límite, por lo que, para aplicar la fórmula de cálculo del intervalo de confianza para la media poblacional indicada en el apartado anterior, habría que comprobar la normalidad de los datos de la población. Pero como, en general, no se dispone de todos los datos de la población, habrá que hacer la comprobación de normalidad con los propios datos de la muestra.

Se puede comprobar si una muestra se adapta a una distribución Normal de varias formas:

- 1) Visualmente comparando el histograma de los datos con la función de densidad Normal
- 2) Visualmente utilizando un diagrama de cuantiles (Q-Q plot)
- 3) Comprobando la regla empírica de la Normal: 68-95-99
- 4) Comprobando la asimetría y apuntamiento
- 5) Realizando un test o contraste de hipótesis de normalidad

Método	Código R	Comentarios	Ejemplo de uso
Histograma datos vs Densidad Normal	<pre>hist(x, freq=FALSE) curve(dnorm(x,m,d) ,a,b, add=TRUE)</pre>	x es el vector con la muestra	<pre>>x=c(5,5,4,6,4,5,5,3,3,6) >hist(x, freq=FALSE, breaks=0:10) >curve(dnorm(x,5,1),0,10 , add=TRUE, col="red")</pre> 
Gráfico Q-Q (Cuantil-Cuantil)	<pre>x = datos qqnorm(x) qqline(x)</pre>	Cuanto más próximos estén los puntos a la recta, más se ajustan los datos a una distribución Normal,	<pre>>x=c(5,5,4,6,4,5,5,3,3,6) >qqnorm(x) >qqline(x,col="red")</pre> 
Diagrama Q-Q con región de confianza del 95%	<pre>install.packages(" car") library(car) qqPlot(x)</pre>	Cuanto más puntos queden dentro de la región, más se ajustan los datos a una distribución Normal.	<pre>>x=c(5,5,4,6,4,5,5,3,3,6) >qqPlot(x)</pre> 
Regla empírica 68-95-99	<pre>n=length(x) length(x[x<=m+d & x>=m-d])/n length(x[x<=m+2*d & x>=m-2*d])/n length(x[x<=m+3*d & x>=m-3*d])/n</pre>	Regla empírica: - En $m \pm d$ se encuentra el 68.27% de la distribución. - En $m \pm 2d$ se encuentra el 95.45% de la distribución - En $m \pm 3d$ se encuentra el 99.73% de la distribución	<pre>> x=c(5,5,4,6,4,5,5,3,3,6) > (n=length(x)) [1] 10 > (m=mean(x)) [1] 4.6 > (d=sd(x)) [1] 1.074968 > length(x[x<=m+d & x>=m-d])/n [1] 0.6 > length(x[x<=m+2*d & x>=m-2*d])/n [1] 1 > length(x[x<=m+3*d & x>=m-3*d])/n [1] 1</pre>

Método	Código R	Comentarios	Ejemplo de uso
Asimetría y Apuntamiento (Curtosis)	<pre>install.packages("e1071") library(e1071) skewness(x)</pre>	Si ³ el valor absoluto del coeficiente de asimetría (skewness) es ≤ 1.5 , y el del coeficiente de apuntamiento (curtosis) es ≤ 1 .	<pre>> x=c(5,5,4,6,4,5,5,3,3,6) > skewness(x) [1] 0.0133508 > kurtosis(x) [1] -0.4657815</pre>
Test de hipótesis (Test de Shapiro-Wilk ⁴)	<pre>shapiro.test(x)</pre>	Si se obtiene un p-value mayor que 0.05 se puede afirmar con un 95% de confianza que se ajusta a una distribución Normal.	<pre>> x=c(5,5,4,6,4,5,5,3,3,6) > shapiro.test(x) Shapiro-Wilk normality test data: x W = 0.89165, p-value = 0.177</pre>

1.1.1 Ejemplo de comprobación de normalidad de una muestra pequeña de notas

Mediante una encuesta, se saben las notas de acceso a la universidad de 74 estudiantes de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá, de una población de 108 matriculados.

El ejemplo consiste en seleccionar aleatoriamente una muestra pequeña de 20 notas y comprobar si la muestra se aproxima a una distribución Normal⁵.

Primero hay que leer los datos de las notas, disponibles en el archivo [encuesta.csv](#):

```
> encuesta = read.csv2("encuesta.csv")
> (nota=encuesta$NOTA)
[1] 8.50 7.10 8.63 8.62 8.20 8.70 7.21 7.63 8.40 8.30
[11] 8.20 9.10 9.79 10.11 8.02 7.31 7.50 8.71 8.34 9.21
[21] 7.80 10.30 7.99 6.90 7.80 10.00 8.59 7.00 8.05 10.80
[31] 7.99 8.55 7.34 6.75 9.56 7.42 6.94 7.21 7.68 10.28
[41] 7.86 10.26 7.27 5.80 7.30 7.14 8.60 7.50 8.00 7.54
[51] 7.29 7.83 6.75 9.81 6.80 6.44 6.65 7.80 10.27 7.60
[61] 7.87 7.00 7.08 7.48 8.07 5.82 6.50 9.90 7.50 6.50
[71] 9.46 8.00 7.80 7.65
```

³ Una distribución Normal tiene un coeficiente de asimetría y de apuntamiento de valor 0. No hay unanimidad entre los expertos sobre los límites alrededor de estos valores para considerar que unos datos son normales. Algunas propuestas, entre ellas la indicada en la tabla, pueden encontrarse en: https://rpubs.com/FabioScielzoOrtiz/Analisis_de_Normalidad_en_R <https://imaging.mrc-cbu.cam.ac.uk/statswiki/FAQ/Simon>

⁴ https://es.wikipedia.org/wiki/Prueba_de_Shapiro-Wilk

⁵ Si no se consigue obtener una muestra pequeña que se aproxime a una distribución Normal después de varios intentos, se puede realizar una transformación previa de los datos, como se explica en el [ANEXO](#) de esta práctica.

Después, seleccionamos aleatoriamente, usando la función `sample()` de R, una muestra de tamaño 20.

```
> (nota.muestra.pequeña=sample(nota, 20))  
[1] 9.21 10.26 10.30 7.50 7.65 6.44 10.80 8.05 7.99 8.40  
[11] 8.50 7.80 7.60 8.59 7.10 7.34 9.79 7.99 6.80 6.94
```


NOTA: Este es un ejemplo, la muestra que se habrá obtenido por cada persona que ejecute la función `sample` en su propio ordenador será diferente.

Ahora podemos aplicar los métodos de comprobación de normalidad.

1) Visualmente comparando el histograma de los datos con la función de densidad Normal

Podemos dibujar un histograma con intervalos de 1 punto, y superponer la curva de la distribución normal.

```
> L=c(5,6,7,8,9,10,11)  
> hist(nota.muestra.pequeña, breaks = L, ylim=c(0,0.4), ylab = "", xlab = "Nota",  
freq = FALSE)  
> curve(dnorm(x,mean(nota.muestra.pequeña),sd(nota.muestra.pequeña)),0,12,  
add=TRUE, col="red")
```




Puede comprobarse que el histograma o distribución de frecuencias de la muestra se asemeja a la forma de la curva de la distribución Normal.

2) Visualmente utilizando un diagrama de cuantiles (Q-Q plot)

El diagrama se puede dibujar utilizando las funciones `qqnorm` y `qqline`.

```
> qqnorm(nota.muestra.pequeña)
> qqline(nota.muestra.pequeña, col="red")
```




Cuanto más se aproximen los puntos de la muestra a la recta, mayor normalidad de los datos. En este caso se comprueba que hay una buena aproximación.

Se puede utilizar un diagrama de cuantiles (Q-Q plot) que incluya una región de confianza del 95% alrededor de la recta. De tal forma que puede afirmarse, con un nivel de confianza del 95%, que si todos los puntos están en esa región, tienen una distribución normal.

Para dibujar la región de confianza, hay que usar la función `qqPlot()` del paquete “car”, que hay que instalar previamente:

```
> if (!require("car")) install.packages("car")
> library(car)
> qqPlot(nota.muestra.pequeña)
```



En este caso puede comprobarse que casi todos los puntos están dentro en la región.

3) Comprobando la regla empírica de la Normal: 68-95-99

En una distribución Normal $N(m, d)$, según la llamada “regla empírica”, se cumple que en el intervalo:

- $m \pm d$ se encuentra el 68.27% de la distribución
- $m \pm 2d$ se encuentra el 95.45% de la distribución
- $m \pm 3d$ se encuentra el 99.73% de la distribución

Se puede comprobar si se cumple en el caso de los datos de las notas de la muestra:

```
> (m=mean(nota.muestra.pequeña))
[1] 8.2525
> (d=sd(nota.muestra.pequeña))
[1] 1.239838
> (n=length(nota.muestra.pequeña))
[1] 20

> length(nota.muestra.pequeña[nota.muestra.pequeña<m+d & nota.muestra.pequeña>m-
d])/n
[1] 0.65

> length(nota.muestra.pequeña[nota.muestra.pequeña<m+2*d &
nota.muestra.pequeña>m-2*d])/n
[1] 0.95

> length(nota.muestra.pequeña[nota.muestra.pequeña<m+3*d &
nota.muestra.pequeña>m-3*d])/n
[1] 1
```

En todos los casos, los valores obtenidos 65-95-100 son parecidos a los de la regla empírica 68-95-99.

4) Comprobando la asimetría y apuntamiento

Hay que instalar el paquete “e1071” para poder usar las funciones de cálculo del coeficiente de asimetría (*skewness*) y del coeficiente de apuntamiento (*kurtosis*).

```
> if (!require("e1071")) install.packages("e1071")
> library(e1071)

> skewness(nota.muestra.pequeña)
[1] 0.6072183

> kurtosis(nota.muestra.pequeña)
[1] -0.8050103
```

Son valores cercanos a los de la Normal (0 en ambos casos) y están dentro del rango propuesto por algunos expertos, de un valor absoluto menor que 1.5 en la asimetría (*skewness*), y menor que 1 en el apuntamiento (*kurtosis*).

5) Realizando un test o contraste de hipótesis de normalidad

El método más utilizado para la comprobación de la normalidad es el conocido test de Shapiro-Wilk, que es adecuado para muestras menores de 50.

```
> shapiro.test(nota.muestra.pequeña)
```

```
Shapiro-Wilk normality test
```

```
data:  nota.muestra.pequeña  
W = 0.93132, p-value = 0.1637
```

Para superar el test, el p-valor debe ser superior al nivel de significación α establecido para la prueba. Normalmente se establece $\alpha = 0.05$, para hacer la prueba con un nivel de confianza del 95%.

Como el p-valor obtenido 0.16 es mayor que 0.05, con un nivel de confianza del 95%, se acepta la hipótesis de que la muestra proviene de una población con distribución Normal.

2. Ejemplo: Intervalo de confianza para la media de calificaciones de estudiantes (muestra grande)

ENUNCIADO

Mediante una encuesta, se saben las calificaciones de acceso a la universidad de 74 estudiantes de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá, de una población de 108 matriculados.

- Calcular los intervalos de confianza para la media poblacional con niveles de confianza del 90%, 95% y 99%, aplicando las fórmulas.
- Calcular los intervalos de confianza para la media poblacional con niveles de confianza del 90%, 95% y 99%, utilizando la función `z.test` del paquete BSDA.
- Dibujar un gráfico con los tres intervalos de confianza para compararlos visualmente.
- Dibujar la función de densidad de probabilidad del estimador con los tres intervalos de confianza

SOLUCIÓN

Primero hay que leer los datos de las notas, disponibles en el archivo [encuesta.csv](#):

```
> encuesta = read.csv2("encuesta.csv")
> (nota=encuesta$NOTA)
[1] 8.50 7.10 8.63 8.62 8.20 8.70 7.21 7.63 8.40 8.30
[11] 8.20 9.10 9.79 10.11 8.02 7.31 7.50 8.71 8.34 9.21
[21] 7.80 10.30 7.99 6.90 7.80 10.00 8.59 7.00 8.05 10.80
[31] 7.99 8.55 7.34 6.75 9.56 7.42 6.94 7.21 7.68 10.28
[41] 7.86 10.26 7.27 5.80 7.30 7.14 8.60 7.50 8.00 7.54
[51] 7.29 7.83 6.75 9.81 6.80 6.44 6.65 7.80 10.27 7.60
[61] 7.87 7.00 7.08 7.48 8.07 5.82 6.50 9.90 7.50 6.50
[71] 9.46 8.00 7.80 7.65
```

a) Calcular los intervalos de confianza para la media poblacional con niveles de confianza del 90%, 95% y 99%.

No se conoce la varianza poblacional y es una muestra grande ($74 > 30$), por lo que se aplican las fórmulas:

$$Li = \bar{x} - z_{\frac{\alpha}{2}} \frac{s}{\sqrt{n}}$$

$$Ls = \bar{x} + z_{\frac{\alpha}{2}} \frac{s}{\sqrt{n}}$$

Los comandos en R serían los siguientes:

```
> n=length(nota)
> m=mean(nota)
> s=sd(nota)
```

```
> #nivel de confianza del 90%
> alfa=1-0.9
> z=qnorm(1-alfa/2,0,1)
> (Li90=m-z*(s/sqrt(n)))
[1] 7.806205
> (Ls90=m+z*(s/sqrt(n)))
[1] 8.23893

> #nivel de confianza del 95%
> alfa=1-0.95
> z=qnorm(1-alfa/2,0,1)
> (Li95=m-z*(s/sqrt(n)))
[1] 7.764756
> (Ls95=m+z*(s/sqrt(n)))
[1] 8.280379

> #nivel de confianza del 99%
> alfa=1-0.99
> z=qnorm(1-alfa/2,0,1)
> (Li99=m-z*(s/sqrt(n)))
[1] 7.683746
> (Ls99=m+z*(s/sqrt(n)))
[1] 8.361389
```

b) Calcular los intervalos de confianza para la media poblacional con niveles de confianza del 90%, 95% y 99%, utilizando la función `z.test` del paquete BSDA.

Con `z.test()` se obtienen los mismos valores.

```
> if (!require("BSDA")) install.packages("BSDA")
> library(BSDA)

> test90=z.test(nota,mu=mean(nota),sigma.x=sd(nota),conf.level=0.90)
> test90$conf.int
[1] 7.806205 8.238930
attr(,"conf.level")
[1] 0.9
>
> test95=z.test(nota,mu=mean(nota),sigma.x=sd(nota),conf.level=0.95)
> test95$conf.int
[1] 7.764756 8.280379
attr(,"conf.level")
[1] 0.95
>
> test99=z.test(nota,mu=mean(nota),sigma.x=sd(nota),conf.level=0.99)
> test99$conf.int
[1] 7.683746 8.361389
attr(,"conf.level")
[1] 0.99
```


Podemos hacer una tabla para comparar los resultados (redondeados con dos decimales), en la que se comprueba que cuanto mayor nivel de confianza menor precisión porque el intervalo es más amplio:

Nivel de confianza	Intervalo de confianza
90%	[7.81, 8.24]
95%	[7.76, 8.28]
99%	[7.68, 8.36]

c) Dibujar un gráfico con los tres intervalos de confianza para compararlos visualmente.

Podemos dibujar primero los puntos de la media en cada intervalo, y luego una línea centrada en cada punto desde el límite inferior al límite superior de cada intervalo.


```
> plot (c(0.90,0.95,0.99),c(m,m,m), xlim=c(0,2),ylim=c(7,9))
> lines(c(0.90,0.90), c(Li90,Ls90))
> lines(c(0.95,0.95), c(Li95,Ls95))
> lines(c(0.99,0.99), c(Li99,Ls99))
```



Se puede un gráfico de mejor calidad usando la función `ggplot()` del paquete `ggplot2`.

```
> if (!require("ggplot2")) install.packages("ggplot2")
> library(ggplot2)

> datos.grafico = data.frame (
  conf = c("0.90", "0.95", "0.99"),
  media = c(m, m, m),
  li = c(Li90,Li95,Li99),
  ls = c(Ls90,Ls95,Ls99)
)
> ggplot(datos.grafico, aes(x=conf,y=media)) + ylim(7,9) +
  xlab("Nivel de confianza") + ylab("Media poblacional") +
  geom_point(size=3) +
  geom_text(aes(y = media, label = round(m,2)), hjust = 1.5, size = 3) +
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
color = "blue") +
  geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
  ggtitle("Intervalos de confianza para la media poblacional") +
  theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```

d) Dibujar la función de densidad de probabilidad del estimador y los tres intervalos de confianza

Se dibuja primero la función de densidad de probabilidad del estimador $\bar{X}$, que es una variable aleatoria $Normal\left(\bar{x}, \frac{s}{\sqrt{n}}\right)$.

```
> curve(dnorm(x,m,s/sqrt(n)),7,9)
```

Después se añaden segmentos para visualizar los tres intervalos con diferentes colores y tramas, y un leyenda para indicar el nivel de confianza de cada intervalo.


```
> segments(0,0,10,0)

> segments(Li90,0, Li90,dnorm(Li90,m,s/sqrt(n)))
> segments(Ls90,0, Ls90,dnorm(Ls90,m,s/sqrt(n)))

> segments(Li95,0, Li95,dnorm(Li95,m,s/sqrt(n)),col=2, lty=2)
> segments(Ls95,0, Ls95,dnorm(Ls95,m,s/sqrt(n)),col=2, lty=2)

> segments(Li99,0, Li99,dnorm(Li99,m,s/sqrt(n)),col=4, lty=3)
> segments(Ls99,0, Ls99,dnorm(Ls99,m,s/sqrt(n)),col=4, lty=3)

> legend("topright", inset = 0.05,
      legend = c("Confianza 90%", "Confianza 95%", "Confianza 99%"),
      lty= c(1,2,3),
      col = c(1, 2, 4), cex=1)
```



3. Ejemplo: Intervalo de confianza para la media de calificaciones de estudiantes (muestra pequeña)

ENUNCIADO

Se trata de utilizar una muestra pequeña de calificaciones de 20 estudiantes, obtenida aleatoriamente a partir de las 74 calificaciones disponibles, y realizar lo siguiente:

- Conseguir una muestra aleatoria de 20 calificaciones con distribución Normal
- Calcular el intervalo de confianza para la media poblacional con nivel de confianza del 95% aplicando las fórmulas.
- Calcular el intervalo de confianza para la media poblacional con nivel de confianza del 95% utilizando la función `t.test`.
- Comparar con el intervalo que se obtuvo utilizando la muestra grande

SOLUCIÓN

a) Conseguir una muestra aleatoria de 20 calificaciones con distribución Normal.

Esto ya se hizo en el ejemplo del apartado 1.1, por lo que podemos utilizar la misma muestra pequeña, que se comprobó que era Normal.

```
> nota.muestra.pequeña
[1]  9.21 10.26 10.30  7.50  7.65  6.44 10.80  8.05  7.99  8.40
[11]  8.50  7.80  7.60  8.59  7.10  7.34  9.79  7.99  6.80  6.94
```

```
> shapiro.test(nota.muestra.pequeña)
```

Shapiro-Wilk normality test

```
data:  nota.muestra.pequeña
W = 0.93132, p-value = 0.1637
```

Como el p-valor obtenido 0.16 es mayor que 0.05, se supera el test de normalidad.

b) Calcular el intervalo de confianza para la media poblacional con nivel de confianza del 95% aplicando las fórmulas.

En este caso, al ser una muestra pequeña ($20 < 30$), se utiliza un estimador con distribución T-Student con $n - 1 = 19 - 1 = 18$ grados de libertad.

No se conoce la varianza poblacional y es una muestra pequeña, por lo que se aplican las fórmulas:

$$Li = \bar{x} - t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$$

$$Ls = \bar{x} + t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}}$$

Los comandos en R serían los siguientes:

```
> (n.muestra.pequeña=length(nota.muestra.pequeña))
[1] 20
> (m.muestra.pequeña=mean(nota.muestra.pequeña))
[1] 8.2525
> (s.muestra.pequeña=sd(nota.muestra.pequeña))
[1] 1.239838
> #nivel de confianza del 95%
> alfa=1-0.95
> (t=qt(1-alfa/2,n-1))
[1] 2.093024
> (Li.muestra.pequeña=m-t*(s/sqrt(n)))
[1] 7.672238
> (Ls.muestra.pequeña=m+t*(s/sqrt(n)))
[1] 8.832762
```

c) Calcular el intervalo de confianza para la media poblacional con nivel de confianza del 95% utilizando la función `t.test`.

Con `t.test()` se obtienen los mismos valores.

```
> test=t.test(nota.muestra.pequeña, conf.level = 0.95)
> test$conf.int
[1] 7.672238 8.832762
attr(,"conf.level")
[1] 0.95
```

d) Comparar con el intervalo que se obtuvo utilizando la muestra grande


Podemos hacer una tabla para comparar los resultados obtenidos con la muestra pequeña y con la muestra grande:

Nivel de confianza	Tamaño muestra	Intervalo de confianza
95%	74	[7.76, 8.28]
95%	20	[7.67, 8.83]

Se puede visualizar la diferencia en un diagrama.

```
> datos.grafico = data.frame (
  tipo = c("Muestra grande", "Muestra pequeña"),
  media = c(m, m.muestra.pequeña),
  li = c(Li95, Li.muestra.pequeña),
  ls = c(Ls95, Ls.muestra.pequeña)
)
```

```
> ggplot(datos.grafico, aes(x=tipo,y=media)) + ylim(7.5,9) +
  xlab("Tipo de muestra") + ylab("Media poblacional") +
  geom_point(size=3) +
  geom_text(aes(y = media, label = round(media,2)), hjust = 1.5, size = 3) +
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
color = "blue") +
  geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
  ggtitle("Intervalos de confianza para la media poblacional") +
  theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```



Se puede comprobar que no se obtienen los mismos intervalos, aunque son parecidos. En este caso, sería más fiable el intervalo de la muestra grande, al haber utilizado más datos de la población de calificaciones.

4. Ejemplo: Intervalo de confianza para las proporción de estudiantes que tienen móvil Android

ENUNCIADO

Mediante una encuesta, se sabe que 50 de 74 estudiantes de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá tienen teléfonos móviles con sistema operativo Android. La población es de 108 estudiantes matriculados. Responder a las siguientes preguntas:

- Calcular los intervalos de confianza para la proporción poblacional de estudiantes que tienen móvil Android con niveles de confianza del 90%, 95% y 99% usando las fórmulas.
- Calcular los intervalos de confianza para la proporción poblacional de estudiantes que tienen móvil Android con niveles de confianza del 90%, 95% y 99%, utilizando la función `binom.confint`.
- Dibujar un gráfico con los tres intervalos de confianza para compararlos visualmente.
- Dibujar la función de densidad de probabilidad del estimador con los tres intervalos de confianza.
- Inferir el mínimo y máximo número de estudiantes de la población que tienen móvil Android con una confianza del 95%.

SOLUCIÓN

a) Calcular los intervalos de confianza para la proporción poblacional de estudiantes que tienen móvil Android con un nivel de confianza del 90%, 95% y 99% usando las fórmulas.

```
> so=encuesta$SO
> n=length(so)
> so.android=so[so=="Android"]
> ng=length(so.android)
> (p=ng/n)
[1] 0.6756757

> # 90%
> alfa=1-0.90
> z=qnorm(1-alfa/2,0,1)
> Li90=p-z*sqrt(p*(1-p)/n)
> Ls90=p+z*sqrt(p*(1-p)/n)
> c(Li90,Ls90)
[1] 0.5861659 0.7651854

> # 95%
> alfa=1-0.95
> z=qnorm(1-alfa/2,0,1)
> Li95=p-z*sqrt(p*(1-p)/n)
> Ls95=p+z*sqrt(p*(1-p)/n)
> c(Li95,Ls95)
[1] 0.5690182 0.7823331

> # 99%
```

```
> alfa=1-0.99
> z=qnorm(1-alfa/2,0,1)
> Li99=p-z*sqrt(p*(1-p)/n)
> Ls99=p+z*sqrt(p*(1-p)/n)
> c(Li99,Ls99)
[1] 0.5355040 0.8158473
```

b) Calcular los intervalos de confianza para la proporción poblacional de estudiantes que tienen móvil Android con niveles de confianza del 90%, 95% y 99%, utilizando la función `binom.confint`.

Con `binom.confint()` se obtienen los mismos valores.

```
> binom.confint(ng, n, conf.level = 0.90, methods = "asymptotic")
  method x  n      mean   lower   upper
1 asymptotic 50 74 0.6756757 0.5861659 0.7651854

> binom.confint(ng, n, conf.level = 0.95, methods = "asymptotic")
  method x  n      mean   lower   upper
1 asymptotic 50 74 0.6756757 0.5690182 0.7823331

> binom.confint(ng, n, conf.level = 0.99, methods = "asymptotic")
  method x  n      mean   lower   upper
1 asymptotic 50 74 0.6756757 0.535504 0.8158473
```

Podemos hacer una tabla para comparar los resultados (redondeados con dos decimales), en la que se comprueba que cuanto mayor nivel de confianza menor precisión porque el intervalo es más amplio:

Nivel de confianza	Intervalo de confianza
90%	[0.59, 0.77]
95%	[0.57, 0.78]
99%	[0.54, 0.82]


c) Dibujar un gráfico con los tres intervalos de confianza para compararlos visualmente.

Podemos dibujarlo usando de nuevo la función `ggplot()`.

```
> datos.grafico = data.frame (
  conf = c("0.90", "0.95", "0.99"),
  prop = c(p, p, p),
  li = c(Li90,Li95,Li99),
  ls = c(Ls90,Ls95,Ls99)
)

> ggplot(datos.grafico, aes(x=conf,y=prop)) + ylim(0.4,0.9) +
  xlab("Nivel de confianza") + ylab("Proporción poblacional") +
  geom_point(size=3) +
  geom_text(aes(y = prop, label = round(p,2)), hjust = 1.5, size = 3) +
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
  color = "blue") +
```

```
geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
ggtitle("Intervalos de confianza para la proporción poblacional") +
theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```



d) Dibujar la función de densidad de probabilidad del estimador y los tres intervalos de confianza


Se dibuja primero la función de densidad de probabilidad del estimador $\hat{P}$, que es una variable aleatoria

$$Normal\left(\hat{p}, \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}\right).$$

```
> curve(dnorm(x,p,sqrt(p*(1-p)/n)),0.4,1)
```


Después se añaden segmentos para visualizar los tres intervalos con diferentes colores y tramas, y un leyenda para indicar el nivel de confianza de cada intervalo.

```
> segments(0.4,0,1,0)
> segments(Li90,0, Li90,dnorm(Li90,p,sqrt(p*(1-p)/n)))
> segments(Ls90,0, Ls90,dnorm(Ls90,p,sqrt(p*(1-p)/n)))
> segments(Li95,0, Li95,dnorm(Li95,p,sqrt(p*(1-p)/n)),col=2, lty=2)
> segments(Ls95,0, Ls95,dnorm(Ls95,p,sqrt(p*(1-p)/n)),col=2, lty=2)
> segments(Li99,0, Li99,dnorm(Li99,p,sqrt(p*(1-p)/n)),col=3, lty=3)
> segments(Ls99,0, Ls99,dnorm(Ls99,p,sqrt(p*(1-p)/n)),col=3, lty=3)
> legend("topright", inset = 0.05,
      legend = c("Confianza 90%", "Confianza 95%", "Confianza 99%"),
      lty= c(1,2,3), col = c(1, 2, 3), cex=1)
```



e) Inferir el mínimo y máximo número de estudiantes de la población que tienen móvil con Android con una confianza del 95%.

Como la población es de 108 estudiantes matriculados, sólo hay que multiplicar este valor por los límites del intervalo de confianza. Pero hay que redondear por defecto el valor mínimo (usando la función `floor`) y por exceso el máximo (usando la función `ceiling`).

```
> floor(108*Li95)
[1] 61
> ceiling(108*Ls95)
[1] 85
```

5. Ejercicios propuestos

- 1) Mediante una encuesta, se sabe el tiempo en minutos del viaje a la Escuela Politécnica de 74 estudiantes de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá, de una población de 108 matriculados. Si se supone que tiene una distribución Normal, responder a las siguientes preguntas:
 - a. Calcular los intervalos de confianza para la media poblacional con niveles de confianza del 90%, 95% y 99%.
 - b. Dibujar una gráfica con los tres intervalos de confianza para compararlos visualmente.

- 2) En caso del ejercicio anterior, obtener una muestra pequeña de 20 estudiantes, y responder a las siguientes preguntas:
 - a. Calcular los intervalos de confianza para la media poblacional con niveles de confianza del 90%, 95% y 99%.

- 3) Mediante una encuesta, se sabe que 26 estudiantes de una muestra de 74 de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá tienen una línea telefónica contratada con las compañías Jazzte/Orange/Simyo. La población es de 108 estudiantes matriculados. Responder a las siguientes preguntas:
 - a. Calcular los intervalos de confianza para la proporción poblacional de estudiantes que tienen una línea telefónica contratada con las compañías Jazzte/Orange/Simyo con un nivel de confianza del 90%, 95% y 99%.
 - b. Estimar el mínimo y máximo número de estudiantes de la población que tienen una línea telefónica contratada con las compañías Jazzte/Orange/Simyo móvil con una confianza del 95%.

ANEXO. Transformación de datos para conseguir Normalidad


Si no se consigue la Normalidad de una muestra borrando datos atípicos, hay que transformar los datos aplicando una función matemática a todos los datos de la muestra. Se recomienda consultar: <https://rpubs.com/JairoAyala/TNM>

Ejemplo con R:

```
datos=c(2,9,10,19,24,26,26,33,38,42,43,43,45,49,52,54,63,75,80,81,88,93,116,123,128,183,194,194,215,355)
```

Histograma:

```
hist(datos)
```



Test de Normalidad:

```
shapiro.test(datos)
      Shapiro-Wilk normality test
data:  datos
W = 0.8162, p-value = 0.0001313
```

No supera el test de normalidad, por lo que hay que transformar los datos.


1) Transformación logarítmica

Una función matemática que suele servir es la función logaritmo:

```
> (datos.trans=log10(datos))
 [1] 0.3010300 0.9542425 1.0000000 1.2787536 1.3802112 1.4149733 1.4149733
 [8] 1.5185139 1.5797836 1.6232493 1.6334685 1.6334685 1.6532125 1.6901961
[15] 1.7160033 1.7323938 1.7993405 1.8750613 1.9030900 1.9084850 1.9444827
[22] 1.9684829 2.0644580 2.0899051 2.1072100 2.2624511 2.2878017 2.2878017
[29] 2.3324385 2.5502284
```

Puede comprobarse que los datos transformados sí son normales.

```
> hist(datos.trans)
```



```
> shapiro.test(datos.trans)
      Shapiro-Wilk normality test
data:  datos.trans
W = 0.94916, p-value = 0.1605
```

Como p-valor >0.05, la muestra transformada sí es Normal.

Se pueden hacer los cálculos de intervalos de confianza y test de hipótesis con los datos transformados, pero cuando haya que completar las tablas del informe, hay que tener en cuenta que las medidas obtenidas se han calculado con los datos transformados, por lo que hay que aplicar a esas medidas una transformación inversa. Se recomienda consultar: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2350916/>

Ejemplo: Si calculamos el intervalo de confianza para la media:

```
> t.test(datos.trans)
      One Sample t-test
data:  datos.trans
t = 20.297, df = 29, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 1.555847 1.904533
sample estimates:
mean of x
 1.73019
```

Obtenemos un intervalo [1.56, 1.90] y una media 1.73.

Pero es para los datos transformados mediante la función logaritmo en base 10 de x, ahora hay que hacer la transformación inversa con la función 10^x para obtenerlo con las unidades de los datos originales.

```
10^1.56 = 36.30781
10^1.90 = 79.43282
```

Entonces el intervalo para la media de los datos originales sería: [36.31, 79.43]

Y la media sería: $10^{1.73} = 53.70$

NOTA: Puede comprobarse que la media no está en el centro del intervalo, esto es porque cuando se hacen estas transformaciones, la media que se obtiene es una media geométrica, no una media aritmética.

2) Transformación Box-Cox

Otra transformación ampliamente utilizada es la denominada Box-Cox.

La fórmula a aplicar depende de un parámetro λ (lambda) que hay que calcular previamente. Se puede utilizar el paquete `MASSEExtra`.

```
> if (!require("MASSEExtra")) install.packages("MASSEExtra")
> library(MASSEExtra)
```

Primero se calcula λ .


```
> modelo=lm(datos~1)
> b=boxcox(modelo)
> (lambda=b$x[which.max(b$y)])
[1] 0.2626263
```

Después se hace la transformación de los datos:

```
> (datos.trans=bc(datos,lambda))
[1] 0.760246 2.972952 3.163196 4.443109 4.965175 5.151544 5.151544
[8] 5.730443 6.090469 6.354087 6.417078 6.417078 6.539890 6.773917
[15] 6.940351 7.047411 7.495886 8.025507 8.227783 8.267113 8.532845
[22] 8.713254 9.461446 9.667216 9.808966 11.149185 11.380240 11.380240
[29] 11.795787 13.992258
```

Puede comprobarse que los datos transformados sí son normales.

```
> hist(datos.trans)
```



```
> shapiro.test(datos.trans)
      Shapiro-Wilk normality test
data:  datos.trans
W = 0.98809, p-value = 0.9777
```

Como p-valor > 0.05 , la muestra transformada sí es Normal.

Entonces se calcula el intervalo de confianza con los datos transformados.

```
> (ic.trans=t.test(datos.trans)$conf.int)
[1] 6.344191 8.510223
attr(,"conf.level")
[1] 0.95
```

Y se hace la transformación inversa para obtener el intervalo con las unidades originales de los datos.

```
> (ic=bc_inv(ic.trans,lambda))
[1] 41.84448 87.38734
```

La media de los datos transformados sería:

```
> mean(datos.trans)
[1] 7.427207
```

Y al realizar la transformación inversa, quedaría:

```
> bc_inv(mean(datos.trans),lambda)
[1] 61.55489
```

Como ocurría en el caso de la transformación logarítmica, tampoco está en el centro del intervalo, ya que, debido a la transformación, no es una media aritmética.