

Estadística

Práctica 8

Intervalos de confianza para la diferencia de parámetros

Contenido

1. Introducción	3
2. Análisis de normalidad y de homogeneidad de varianzas	8
2.1 Análisis de normalidad	8
2.2 Análisis de homogeneidad de varianzas	8
3. Ejemplo: Intervalo de confianza para la diferencia de medias de calificaciones de estudiantes del turno de mañana y del turno de tarde (muestras grandes e independientes)	10
4. Ejemplo: Intervalo de confianza para la diferencia de medias de calificaciones de estudiantes del turno de mañana y del turno de tarde (muestras pequeñas e independientes)	16
5. Ejemplo: Intervalo de confianza para la diferencia de medias del tiempo que duermen los estudiantes en días laborables y en días festivos (muestras grandes y pareadas)	22
6. Ejemplo: Intervalo de confianza para la diferencia de proporciones de estudiantes que tienen móvil Android en el turno de mañana y en el turno de tarde (muestras grandes e independientes)	24
7. Ejercicios propuestos	29

1. Introducción

Con esta práctica se utiliza R y RStudio para estimar (inferir) con un nivel de confianza determinado, el intervalo en el que se encuentra la diferencia de los parámetros (media y proporción) de dos poblaciones a partir de una muestra de cada una de las poblaciones.

Como en la práctica anterior, se puede calcular el intervalo en el que se puede asegurar que se encuentra la diferencia con un determinado nivel de confianza, obteniendo lo que se conoce como Intervalo de Confianza, con un límite inferior L_i y un límite superior L_s :

$$\text{Intervalo de confianza con nivel de confianza } 1 - \alpha = (L_i, L_s)$$

En la expresión del nivel de confianza aparece un valor α (alfa) que se denomina nivel de error o nivel de significación, y representa lo contrario que el nivel de confianza.

Cuando el intervalo de confianza:

- Sí contiene el valor 0, se puede afirmar que la diferencia de los parámetros de ambas poblaciones NO es significativa.
- No contiene el valor 0, se puede afirmar que la diferencia entre los parámetros de ambas poblaciones SÍ es significativa y además:
 - Si los extremos del intervalo son negativos, se puede afirmar que el parámetro de la primera población es menor que el de la segunda.
 - Si los extremos del intervalo son positivos, se puede afirmar que el parámetro de la primera población es mayor que el de la segunda.

En la siguiente tabla se indican las fórmulas para calcular las diferencias de los parámetros poblacionales y su posible programación utilizando el lenguaje R. En el caso de la media se distingue entre muestras independientes y muestras relacionadas o pareadas. En este último caso realmente se comparan dos variables diferentes, y se manejan parejas de valores, normalmente un valor de la variable en una situación (por ejemplo, el peso de una persona) y otro valor de la misma variable en otra situación (por ejemplo, el peso de la misma persona al finalizar una dieta).

Diferencia a calcular	Varianzas conocidas	Intervalo de confianza (L_i , L_s)	Código R
Diferencia de medias de dos poblaciones ($\mu_1 - \mu_2$)	Si	$L_i = \bar{x} - \bar{y} - z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}$ $L_s = \bar{x} - \bar{y} + z_{\frac{\alpha}{2}} \sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}}$	<pre>x=muestra de X y=muestra de Y n=length(x) m=length(y) mx=mean(x) my=mean(y) dx^2=varianza poblacional de X dy^2=varianza poblacional de Y z=qnorm(1-alfa/2,0,1) Li=mx-my-z*sqrt((dx^2/n)+(dy^2/m)) Ls=mx-my+z*sqrt((dx^2/n)+(dy^2/m))</pre>
	No $n, m \geq 30$	$L_i = \bar{x} - \bar{y} - z_{\frac{\alpha}{2}} \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}$ $L_s = \bar{x} - \bar{y} + z_{\frac{\alpha}{2}} \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}$	<pre>x=muestra de X y=muestra de Y n=length(x) m=length(y) mx=mean(x) my=mean(y) sx=sd(x) sy=sd(y) z=qnorm(1-alfa/2,0,1) Li=mx-my-z*sqrt((sx^2/n)+(sy^2/m)) Ls=mx-my+z*sqrt((sx^2/n)+(sy^2/m))</pre>
	No $n, m < 30$ $\sigma_X = \sigma_Y$	$L_i = \bar{x} - \bar{y} - \left(t_{\frac{\alpha}{2}, n+m-2}\right) (s_p) \sqrt{\frac{1}{n} + \frac{1}{m}}$ $L_s = \bar{x} - \bar{y} + \left(t_{\frac{\alpha}{2}, n+m-2}\right) (s_p) \sqrt{\frac{1}{n} + \frac{1}{m}}$ $s_p = \sqrt{\frac{(n-1)s_X^2 + (m-1)s_Y^2}{n+m-2}}$	<pre>x=muestra de X y=muestra de Y n=length(x) m=length(y) mx=mean(x) my=mean(y) sx=sd(x) sy=sd(y) sp=sqrt(((n-1)*sx^2+(m-1)*sy^2)/(n+m-2)) t=qt(1-alfa/2,n+m-2) Li=mx-my-t*sp*sqrt((1/n)+(1/m)) Ls=mx-my+t*sp*sqrt((1/n)+(1/m))</pre>
	No $n, m < 30$ $\sigma_X \neq \sigma_Y$	$L_i = \bar{x} - \bar{y} - t_{\frac{\alpha}{2}, v} \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}$ $L_s = \bar{x} - \bar{y} + t_{\frac{\alpha}{2}, v} \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}$ $v = \frac{\left(\frac{s_X^2}{n} + \frac{s_Y^2}{m}\right)^2}{\frac{s_X^4}{n^2(n-1)} + \frac{s_Y^4}{m^2(m-1)}}$	<pre>x=muestra de X y=muestra de Y n=length(x) m=length(y) mx=mean(x) my=mean(y) sx=sd(x) sy=sd(y) v=((sx^2/n+sy^2/m)^2)/((sx^4/(n^2*(n-1)))+(sy^4/(m^2*(m-1)))) t=qt(1-alfa/2, v) Li=mx-my-t*sqrt((sx^2/n)+(sy^2/m)) Ls=mx-my+t*sqrt((sx^2/n)+(sy^2/m))</pre>

Diferencia a calcular	Varianzas conocidas	Intervalo de confianza (L_i , L_s)	Código R
	Muestras pareadas $n \geq 30$	$L_i = \bar{d} - z_{\frac{\alpha}{2}} \frac{s_D}{\sqrt{n}}$ $L_s = \bar{d} + z_{\frac{\alpha}{2}} \frac{s_D}{\sqrt{n}}$ $D = X - Y$	<pre>d=muestra de X - muestra de Y n=length(d) m=mean(d) s=sd(d) z=qnorm(1-alfa/2,0,1) Li=m-z*(s/sqrt(n)) Ls=m+z*(s/sqrt(n))</pre>
	Muestras pareadas $n < 30$	$L_i = \bar{d} - t_{\frac{\alpha}{2}, n-1} \frac{s_D}{\sqrt{n}}$ $L_s = \bar{d} + t_{\frac{\alpha}{2}, n-1} \frac{s_D}{\sqrt{n}}$ $D = X - Y$	<pre>d= muestra de X - muestra de Y n=length(d) m=mean(d) s=sd(d) t=qt(1-alfa/2,n-1) Li=m-t*(s/sqrt(n)) Ls=m+t*(s/sqrt(n))</pre>

Diferencia a calcular	Muestras	Intervalo de confianza (L_i , L_s)	Código R
Diferencia de proporciones de dos poblaciones ($p_1 - p_2$)	$n, m \geq 30$	$L_i = \hat{p}_1 - \hat{p}_2 - z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$ $L_s = \hat{p}_1 - \hat{p}_2 + z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$	<pre>n1,n2=tamaño de muestras p1,p2=proporciones en muestras z=qnorm(1-alfa/2,0,1) Li=p1-p2-z*sqrt((p1*(1-p1)/n1)+(p2*(1-p2)/n2)) Ls=p1-p2+z*sqrt((p1*(1-p1)/n1)+(p2*(1-p2)/n2))</pre>

Existen en R funciones predefinidas que se pueden utilizar para los cálculos de algunos intervalos sin tener que programar las fórmulas de la tabla anterior.

Son las funciones predefinidas `t.test()` y `prop.test()`, y la función `z.test()` del paquete `BSDA`.

Diferencia a calcular	Varianzas conocidas	Código R	Ejemplo
Diferencia de medias de dos poblaciones ($\mu_1 - \mu_2$)	Si	<pre>test= z.test(muestra de X, muestra de Y, sigma.x=desviación poblacional de X, sigma.y=desviación poblacional de Y, conf.level=1-alfa) Intervalo: test\$conf.int</pre>	<pre>> x=muestra de X > y=muestra de Y > dx=1.5 > dy=2.3 > alfa=0.05 > test=z.test(x, y, sigma.x = dx, sigma.y = dy, conf.level = 1-alfa) > test\$conf.int [1] "Resultado"</pre>
	No $n, m \geq 30$	<pre>test= z.test(muestra de X, muestra de Y, sigma.x=desviación muestral de X, sigma.y=desviación muestral de Y, conf.level=1-alfa) Intervalo: test\$conf.int</pre>	<pre>> x=rnorm(40,5,1) > y=rnorm(50,6,1) > alfa=0.05 > test=z.test(x, y, sigma.x = sd(x), sigma.y = sd(y), conf.level = 1-alfa) > test\$conf.int [1] -1.1310858 -0.2934948</pre>
	No $n, m < 30$ $\sigma_X = \sigma_Y$ Datos Normales	<pre>test= t.test(muestra de X, muestra de Y, conf.level=1-alfa, var.equal=TRUE) Intervalo: test\$conf.int</pre>	<pre>> x=c(4.5, 5.2, 5.3, 4.7, 5, 6.3) > y=c(6.7, 5.1, 6.1, 4.3) > alfa=0.05 > test=t.test(x, y, conf.level = 1- alfa, var.equal=TRUE) > test\$conf.int [1] -1.6043880 0.8377213</pre>
	No $n, m < 30$ $\sigma_X \neq \sigma_Y$ Datos Normales	<pre>test= t.test(muestra de X, muestra de Y, conf.level=1-alfa, var.equal=FALSE) Intervalo: test\$conf.int</pre>	<pre>> x=c(4.5, 5.2, 5.3, 4.7, 5, 6.3) > y=c(6.7, 5.1, 6.1, 4.3) > alfa=0.05 > test=t.test(x, y, conf.level = 1- alfa, var.equal=FALSE) > test\$conf.int [1] -1.962490 1.195824</pre>
	Muestras pareadas $n \geq 30$	<pre>test= z.test(diferencia entre las muestras, sigma.x=desviación muestral de la diferencia entre las muestras, conf.level=1-alfa) Intervalo: test\$conf.int</pre>	<pre>> x=rnorm(40,5,1) > y=rnorm(40,6,1) > alfa=0.05 > d=x-y > test=z.test(d, sigma.x = sd(d), conf.level = 1-alfa) > test\$conf.int [1] -1.4781060 -0.4467718</pre>
	Muestras pareadas $n < 30$ Datos Normales	<pre>test= t.test(muestra de X, muestra de Y, conf.level=1-alfa, paired=TRUE) Intervalo: test\$conf.int</pre>	<pre>> x=c(4.5, 5.2, 5.3, 4.7) > y=c(6.7, 5.1, 6.1, 4.3) > alfa=0.05 > test=t.test(x, y, conf.level = 1- alfa, paired=TRUE) > test\$conf.int [1] -2.482374 1.232374</pre>

Diferencia a calcular	Muestras	Código R	Ejemplo
Diferencia de proporciones de dos poblaciones ($p_1 - p_2$)	$n, m \geq 30$	<pre>test= prop.test(c (ng1,ng2) , c (n1,n2), conf.level=1- alfa, correct=FALSE)</pre> Intervalo: test\$conf.int NOTA: n1 y n2 son los tamaños de las muestras. ng1 y ng2 son los tamaños de los grupos de datos de las muestras para los que se calculan las proporciones, es decir, las proporciones muestrales serían $p1=ng1/n1$ y $p2=ng2/n2$.	<pre>> n1=100 > n2=100 > ng1=20 > ng2=70 > alfa=0.05 > test=prop.test(c (ng1,ng2) , c (n1,n2), conf.level = 1-alfa, correct=FALSE) > test\$conf.int [1] -0.61922 -0.38078</pre>

2. Análisis de normalidad y de homogeneidad de varianzas

2.1 Análisis de normalidad

Como ocurría en el cálculo de intervalos de confianza para la media de una población, a partir de una muestra pequeña ($n < 30$), también en el caso de los intervalos de confianza para la diferencia de medias, a partir de muestras pequeñas ($n, m < 30$) es necesario que los datos provengan de poblaciones que se aproximen a una distribución Normal. Por lo que habrá que hacer una comprobación de normalidad, con los métodos ya conocidos:

- 1) Visualmente comparando el histograma de los datos con la función de densidad Normal
- 2) Visualmente utilizando un diagrama de cuantiles (Q-Q plot)
- 3) Comprobando la regla empírica de la Normal: 68-95-99
- 4) Comprobando la asimetría y apuntamiento
- 5) Realizando un test o contraste de hipótesis de normalidad

Por ejemplo, se podría comprobar realizando el test de Shapiro-Wilk con las muestras siguientes:

```
> (x=c(4.5, 5.2, 5.3, 4.7, 5, 6.3))
[1] 4.5 5.2 5.3 4.7 5.0 6.3
> (y=c(6.7, 5.1, 6.1, 4.3))
[1] 6.7 5.1 6.1 4.3

> shapiro.test(x)
      Shapiro-Wilk normality test
data:  x
W = 0.90542, p-value = 0.4069

> shapiro.test(y)
      Shapiro-Wilk normality test
data:  y
W = 0.97257, p-value = 0.8573
```

En los dos casos, los p-valores son superiores a 0.05, por lo que, con un nivel de confianza del 95% se puede asumir que ambas muestras provienen de poblaciones con datos que se aproximan a distribuciones normales.

2.2 Análisis de homogeneidad de varianzas

Como se indica en la tabla del apartado 1, cuando se calcula un intervalo de confianza para la diferencia de medias utilizando muestras pequeñas y datos Normales, hay que diferenciar si las varianzas de las dos poblaciones son iguales o no, ya que las fórmulas son diferentes en los dos casos.

Se puede realizar la conocida como prueba o test de Levene¹, que plantea la hipótesis de que las varianzas son iguales, frente a la alternativa de que son diferentes, considerando que las dos poblaciones son Normales. Para realizar el test de Levene se puede utilizar la función `leveneTest()` del paquete “car”.

```
> if (!require("car")) install.packages("car")
> library(car)
```

Para poder usar la función `leveneTest()`, primero hay que preparar los datos en un único dataframe con dos columnas, una con todos los valores y otra que indique a qué muestra pertenece cada dato.

```
> (dX=data.frame(VALOR=x, MUESTRA=rep(c("x"),times=length(x))))
  VALOR MUESTRA
1   4.5      x
2   5.2      x
3   5.3      x
4   4.7      x
5   5.0      x
6   6.3      x
> (dY=data.frame(VALOR=y, MUESTRA=rep(c("y"),times=length(y))))
  VALOR MUESTRA
1   6.7      y
2   5.1      y
3   6.1      y
4   4.3      y
> (d=rbind(dX,dY))
  VALOR MUESTRA
1   4.5      x
2   5.2      x
3   5.3      x
4   4.7      x
5   5.0      x
6   6.3      x
7   6.7      y
8   5.1      y
9   6.1      y
10  4.3      y
> leveneTest(d$VALOR,d$MUESTRA)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group 1  2.3753 0.1618
      8
```

El p-valor=0.1618 es superior a 0.05, por lo que, con un nivel de confianza del 95%, se puede suponer que las varianzas poblacionales son iguales.

¹ https://es.wikipedia.org/wiki/Prueba_de_Levene

3. Ejemplo: Intervalo de confianza para la diferencia de medias de calificaciones de estudiantes del turno de mañana y del turno de tarde (muestras grandes e independientes)

ENUNCIADO

Mediante una encuesta, se saben las calificaciones de acceso a la universidad de 42 estudiantes del turno de mañana y de 32 estudiantes del turno de tarde de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá, de una población de 52 matriculados en el turno de mañana y 56 en el turno de tarde. Responder a las siguientes preguntas:

- Dibujar un diagrama con los intervalos de confianza de las medias de las dos poblaciones por separado, con un nivel de confianza del 95%, para hacer una comparación visual.
- Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando fórmulas.
- Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando fórmulas la función `z.test` del paquete BSDA.
- Dibujar el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde
- Dibujar la función de densidad de probabilidad del estimador (sin estandarizar) de la diferencia de medias poblacionales.
- ¿Existe una diferencia significativa entre las medias de las dos poblaciones (mañana y tarde)?

SOLUCIÓN

Primero leemos el archivo [encuesta.csv](#) y guardamos en dos vectores las muestras de notas del turno de mañana (grupos A1 y A2) y del turno de tarde (grupos B1 y B2):

```
> encuesta=read.csv2("encuesta.csv")

> encuesta.mañana=encuesta[(encuesta$GRUPO=="A1") | (encuesta$GRUPO=="A2"), ]
> encuesta.tarde=encuesta[(encuesta$GRUPO=="B1") | (encuesta$GRUPO=="B2"), ]
> notaM=encuesta.mañana$NOTA
> notaT=encuesta.tarde$NOTA
```

- Dibujar un diagrama con los intervalos de confianza de las dos poblaciones por separado, con un nivel de confianza del 95%, para hacer una comparación visual.

El intervalo de confianza de la media poblacional de los alumnos del turno de mañana es:

```
> nM=length(notaM)
> mM=mean(notaM)
> sM=sd(notaM)
> alfa=1-0.95
> z=qnorm(1-alfa/2,0,1)
> (LiM=mM-z*(sM/sqrt(nM)))
[1] 8.024987
> (LsM=mM+z*(sM/sqrt(nM)))
[1] 8.672632
```

El intervalo de confianza de los alumnos de tarde es:

```
> nT=length(notaT)
> mT=mean(notaT)
> sT=sd(notaT)
> alfa=1-0.95
> z=qnorm(1-alfa/2,0,1)
> (LiT=mT-z*(sT/sqrt(nT)))
[1] 7.220355
> (LsT=mT+z*(sT/sqrt(nT)))
[1] 7.968395
```

Se podrían haber calculado con la función `z.test`, y se habrían obtenido lo mismos intervalos que con las fórmulas.

```
> z.test(notaM,sigma.x=sd(notaM),conf.level=0.95)
95 percent confidence interval:
 8.024987 8.672632

> z.test(notaT,sigma.x=sd(notaT),conf.level=0.95)
95 percent confidence interval:
 7.220355 7.968395
```


Podemos dibujar los intervalos utilizando la función `ggplot()` del paquete `ggplot2`.

```
> if (!require("ggplot2")) install.packages("ggplot2")
> library(ggplot2)

datos.grafico = data.frame (
  turno = c("Mañana", "Tarde"),
  media = c(mM, mT),
  li = c(LiM,LiT),
  ls = c(LsM,LsT)
)

ggplot(datos.grafico, aes(x=turno,y=media)) + ylim(7,9) +
  xlab("Turno") + ylab("Media poblacional") +
  geom_point(size=3) +
  geom_text(aes(y = media, label = round(media,2)), hjust = 1.5, size = 3) +
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
color = "blue") +
  geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
```

```
ggtitle("Intervalos al 95% para la media poblacional en cada turno") +  
theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```



Vemos que los dos intervalos no se solapan, lo cual es un indicio de que no va a haber coincidencia de medias, aunque lo tendremos que demostrar calculando el intervalo de la diferencia de medias.

b) Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando fórmulas.

Las fórmulas que hay que aplicar son:

$$L_i = \bar{x} - \bar{y} - z_{\frac{\alpha}{2}} \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}$$

$$L_s = \bar{x} - \bar{y} + z_{\frac{\alpha}{2}} \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}$$

```
> alfa = 1-0.95  
> z=qnorm(1-alfa/2,0,1)  
> (Li=mM-mT-z*sqrt((sM^2/nM)+(sT^2/nT)))  
[1] 0.2597101  
> (Ls=mM-mT+ z*sqrt((sM^2/nM)+(sT^2/nT)))  
[1] 1.249159
```

El intervalo de confianza para la diferencia de medias entre los grupos de mañana y tarde es [0.2597101, 1.249159]. Redondeando a dos decimales es [0.26, 1.25].

c) Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando la función `z.test` del paquete `BSDA`.

```
> if (!require("BSDA")) install.packages("BSDA")
> library(BSDA)

> z.test(notaM, notaT, sigma.x=sM, sigma.y=sT, conf.level=0.95)
95 percent confidence interval:
 0.2597101 1.2491589
```

Podemos comprobar que se obtiene el mismo intervalo que aplicando las fórmulas.

Se pueden obtener los límites del intervalo en dos variables, utilizando la función `z.test` de la siguiente forma:

```
> resultado.z.test=z.test(notaM, notaT, sigma.x=sM, sigma.y=sT, conf.level=0.95)


> (Li=resultado.z.test$conf.int[1])
[1] 0.2597101
> (Ls=resultado.z.test$conf.int[2])
[1] 1.249159
```

d) Dibujar el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde

Se puede dibujar un diagrama con el intervalo usando la función `ggplot()`.

```
datos.grafico = data.frame (
  conf = c("95%"),
  dif.medias = c(mM-mT),
  li = c(Li),
  ls = c(Ls)
)

ggplot(datos.grafico, aes(x=conf, y=dif.medias)) + ylim(-1,2) +
  xlab("Confianza") + ylab("Diferencia de medias poblacionales") +
  geom_point(size=3) +
  geom_text(aes(y = dif.medias, label = round(dif.medias,2)), hjust = 1.5, size =
3) +
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
color = "blue") +
  geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
  ggtitle("Intervalo al 95% para la diferencia de medias") +
  theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```




e) Dibujar la función de densidad de probabilidad del estimador (sin estandarizar) de la diferencia de medias poblacionales

El estimador sin estandarizar es una variable aleatoria con distribución Normal:

$$Normal \left(\bar{x} - \bar{y}, \sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}} \right)$$

Por tanto, la función de densidad de probabilidad se puede dibujar de la siguiente forma:

```
> curve(dnorm(x,mM-mT,sqrt((sM^2/nM)+(sT^2/nT))),-1,2)
> segments(-1,0,2,0)
> segments(Li,0, Li,dnorm(Li,m,sqrt((sM^2/nM)+(sT^2/nT))))
> segments(Ls,0, Ls,dnorm(Li,m,sqrt((sM^2/nM)+(sT^2/nT))))
> text(Li,0,paste("Li=",as.character(round(Li,2))),cex=0.8)
> text(Ls,0,paste("Ls=",as.character(round(Ls,2))),cex=0.8)
```



f) ¿Existe una diferencia significativa entre las medias de las dos poblaciones (mañana y tarde)?

Como el 0 no está incluido en el intervalo $[0.26, 1.25]$, se puede afirmar con un nivel de confianza del 95% que ***Sí hay diferencia significativa entre la media de las calificaciones de los estudiantes de los turnos de mañana y tarde, y que la media de las calificaciones de los estudiantes del turno de mañana es mayor que la media de las calificaciones de los estudiantes del turno de tarde***, porque los extremos de los intervalos son positivos.

4. Ejemplo: Intervalo de confianza para la diferencia de medias de calificaciones de estudiantes del turno de mañana y del turno de tarde (muestras pequeñas e independientes)

ENUNCIADO

Se trata de repetir el ejemplo del apartado anterior, pero utilizando muestras pequeñas ($n, m < 30$) en lugar de muestras grandes.

- Generar una muestra pequeña Normal de tamaño 20 para las notas del turno de mañana y otra muestra Normal de tamaño 20 para el turno de tarde. Guardarlas en dos archivos de datos.
- Comprobar la homogeneidad de las varianzas de las notas de los dos turnos.
- Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando fórmulas.
- Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando la función `t.test`.
- Dibujar un diagrama con los intervalos para la diferencia de medias usando muestras grandes y usando muestras pequeñas.
- Comparar los resultados respecto a usar muestras grandes.

SOLUCIÓN

a) Generar una muestra pequeña Normal de tamaño 20 para las notas del turno de mañana y otra muestra Normal de tamaño 20 para el turno de tarde. Guardarlas en dos archivos de datos.

Es conveniente repetir la generación de las muestras pequeñas hasta conseguir que superen un test de normalidad como el de Shapiro-Wilk, es decir un $p\text{-valor} > 0.05$.

```
> (notaM.muestra.pequeña=sample(notaM, 20))
[1] 7.21 7.99 7.86 7.80 9.79 8.62 8.55 8.02 8.05 6.94
[11] 7.42 8.30 8.71 8.59 7.00 7.10 7.34 10.26 10.11 9.56
```

```
> shapiro.test(notaM.muestra.pequeña)
Shapiro-Wilk normality test
data:  notaM.muestra.pequeña
W = 0.92413, p-value = 0.119
```


```
> (notaT.muestra.pequeña=sample(notaT, 20))
[1] 6.75 7.65 10.27 7.80 9.46 5.82 6.80 7.80 7.54 8.07
[11] 7.83 8.60 5.80 6.44 7.27 7.08 7.29 7.00 6.50 7.30
```

```
> shapiro.test(notaT.muestra.pequeña)
```

```
Shapiro-Wilk normality test
data: notaT.muestra.pequeña
W = 0.93551, p-value = 0.197
```


Podemos confirmar gráficamente que se aproximan a una distribución Normal.

```
> par(mfrow=c(1,2))
> L=c(5,6,7,8,9,10,11)
> hist(notaM.muestra.pequeña, breaks = L, main="Turno Mañana (muestra pequeña)",
ylim=c(0,0.4), ylab = "", xlab = "Nota", freq = FALSE)
> curve(dnorm(x,mean(notaM.muestra.pequeña),sd(notaM.muestra.pequeña)),0,12,
add=TRUE, col="red")
> hist(notaT.muestra.pequeña, breaks = L, main="Turno Tarde (muestra pequeña)",
ylim=c(0,0.4), ylab = "", xlab = "Nota", freq = FALSE)
> curve(dnorm(x,mean(notaT.muestra.pequeña),sd(notaT.muestra.pequeña)),0,12,
add=TRUE, col="red")
```



También se puede generar un diagrama QQ con región de aceptación, y cuanto mayor número de datos estén dentro de la región mejor se aproxima a la Normal.

```
> qqPlot(notaM.muestra.pequeña, main = "Mañana")
> qqPlot(notaT.muestra.pequeña, main = "Tarde")
```



IMPORTANTE: Las muestras pequeñas serán diferentes para cada persona que realice esta práctica, pues la función `sample` habrá seleccionado unas notas diferentes. Por tanto, los resultados para muestras pequeñas en los siguientes apartados de esta práctica no coincidirán.

Las muestras pequeñas se pueden guardar en fichero diferentes usando los siguientes comandos:

```
> write.csv2(notaM.muestra.pequeña, "20notasmañana.csv")
> write.csv2(notaT.muestra.pequeña, "20notastarde.csv")
```

De esta forma, si en algún momento borramos las variables del proyecto, podemos recuperar los datos con los siguientes comandos:

```
> x=read.csv2("20notasmañana.csv")
> (notaM.muestra.pequeña=x$x)
[1] 7.21 7.99 7.86 7.80 9.79 8.62 8.55 8.02 8.05 6.94
[11] 7.42 8.30 8.71 8.59 7.00 7.10 7.34 10.26 10.11 9.56

> x=read.csv2("20notastarde.csv")
> (notaT.muestra.pequeña=x$x)
[1] 6.75 7.65 10.27 7.80 9.46 5.82 6.80 7.80 7.54 8.07
[11] 7.83 8.60 5.80 6.44 7.27 7.08 7.29 7.00 6.50 7.30
```

b) Comprobar la homogeneidad de las varianzas de las notas de los dos turnos.

Como se explica en el apartado 2.2, se puede realizar un test de Levene, usando la función `leveneTest` del paquete `car`.

Como en aquel caso, primero hay que preparar los datos en un único dataframe con dos columnas, una con todos los valores y otra que indique a qué turno pertenece cada nota.

```
> dM=data.frame(NOTA=notaM.muestra.pequeña, TURNO=rep(c("Mañana"), times=20))
> dT=data.frame(NOTA=notaT.muestra.pequeña, TURNO=rep(c("Tarde"), times=20))
> d=rbind(dM, dT)

> leveneTest(d$NOTA, d$TURNO)
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group 1  0.0041 0.9492
      38
```

El p-valor es 0.9492, muy superior a 0.05, por lo que se puede suponer que las varianzas son iguales, y realizar el contraste de hipótesis usando la función `t.test` con el parámetro `var.equal=TRUE`.

c) Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando fórmulas.

Como las varianzas poblacionales son desconocidas pero iguales (según el resultado del test de Levene), las fórmulas que hay que aplicar son:

$$L_i = \bar{x} - \bar{y} - \left(t_{\frac{\alpha}{2}, n+m-2}\right)(s_p) \sqrt{\frac{1}{n} + \frac{1}{m}}$$

$$L_s = \bar{x} - \bar{y} + \left(t_{\frac{\alpha}{2}, n+m-2}\right)(s_p) \sqrt{\frac{1}{n} + \frac{1}{m}}$$

$$s_p = \sqrt{\frac{(n-1)s_x^2 + (m-1)s_y^2}{n+m-2}}$$

```
> (alfa = 1-0.95)
[1] 0.05

> (x=notaM.muestra.pequeña)
[1] 7.21 7.99 7.86 7.80 9.79 8.62 8.55 8.02 8.05 6.94
[11] 7.42 8.30 8.71 8.59 7.00 7.10 7.34 10.26 10.11 9.56
> (y=notaT.muestra.pequeña)
[1] 6.75 7.65 10.27 7.80 9.46 5.82 6.80 7.80 7.54 8.07
[11] 7.83 8.60 5.80 6.44 7.27 7.08 7.29 7.00 6.50 7.30

> (n=length(x))
[1] 20
> (m=length(y))
[1] 20

> (mx=mean(x))
[1] 8.261
> (my=mean(y))
[1] 7.4535

> (sx=sd(x))
[1] 1.022288
> (sy=sd(y))
[1] 1.09475

> (sp=sqrt(((n-1)*sx^2+(m-1)*sy^2)/(n+m-2)))
[1] 1.059139

> (t=qt(1-alfa/2,n+m-2))
[1] 2.024394

> (Li=mx-my-t*sp*sqrt((1/n)+(1/m)))
[1] 0.1294716
> (Ls=mx-my+t*sp*sqrt((1/n)+(1/m)))
[1] 1.485528
```

El intervalo de confianza para la diferencia de medias entre los grupos de mañana y tarde es [0.1294716, 1.485528]. Redondeando a dos decimales es [0.13, 1.49].

d) Calcular el intervalo de confianza para la diferencia de medias poblacionales de las calificaciones de los turnos de mañana y tarde con nivel de confianza del 95%, utilizando la función `t.test`.

```
> test= t.test(x,y, conf.level=1-alfa, var.equal=TRUE)
> test$conf.int
[1] 0.1294716 1.4855284
attr(,"conf.level")
[1] 0.95
```


Podemos comprobar que se obtiene el mismo intervalo que aplicando las fórmulas.

e) Dibujar un diagrama con los intervalos para la diferencia de medias usando muestras grandes y usando muestras pequeñas.

```
> (mM.muestra.pequeña=mean(notaM.muestra.pequeña))
[1] 8.261
> (mT.muestra.pequeña=mean(notaT.muestra.pequeña))
[1] 7.4535

datos.grafico = data.frame (
  tamaño = c("Muestras grandes", "Muestras pequeñas"),
  dif.medias = c(mM-mT, mM.muestra.pequeña-mT.muestra.pequeña),
  li = c(Li, Li.muestra.pequeña),
  ls = c(Ls, Ls.muestra.pequeña)
)

ggplot(datos.grafico, aes(x=tamaño,y=dif.medias)) + ylim(-1,2) +
  xlab("Tamaño de muestras") + ylab("Diferencia de medias poblacionales") +
  geom_point(size=3) +
  geom_text(aes(y = dif.medias, label = round(dif.medias,2)), hjust = 1.5, size =
3) +
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
color = "blue") +
  geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
  ggtitle("Intervalo al 95% para la diferencia de medias") +
  theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```



f) Comparar los resultados respecto a usar muestras grandes.

Los intervalos obtenidos según el tamaño de las muestras son los siguientes:

Tamaño de las muestras	Intervalo para la diferencia de medias
Muestras grandes (mañana=42, tarde=32)	[0.26, 1.25]
Muestras pequeñas (mañana=20, tarde=20)	[0.13, 1.49]

Puede comprobarse que el intervalo con muestras pequeñas es más amplio que con muestras grandes, pero la conclusión final en ambos casos es la misma, ya que como el 0 no está incluido en los intervalos, se puede afirmar en ambos casos, con un nivel de confianza del 95%, que Sí hay diferencia significativa entre la media de las calificaciones de los estudiantes de los turnos de mañana y tarde, y que la media de las calificaciones de los estudiantes del turno de mañana es mayor que la media de las calificaciones de los estudiantes del turno de tarde, porque los extremos de los intervalos son positivos.

5. Ejemplo: Intervalo de confianza para la diferencia de medias del tiempo que duermen los estudiantes en días laborables y en días festivos (muestras grandes y pareadas)

ENUNCIADO

Mediante la encuesta del ejemplo anterior se sabe el tiempo que duermen los días laborables 74 estudiantes de una población de 108 matriculados. Se ha averiguado que los días festivos los estudiantes duermen un 10% más de tiempo que en días laborables. Si se supone que el tiempo que duermen tanto en días laborables como en festivos tiene una distribución Normal, responder a la siguiente pregunta:

- Calcular el intervalo de confianza para la diferencia de medias poblacionales del tiempo que duermen los estudiantes en días laborables y festivos, con nivel de confianza del 95%.
- Calcular el intervalo de confianza con la función `z.test` del paquete BSDA
- ¿Existe una diferencia significativa entre las medias de las dos poblaciones?

SOLUCIÓN

- Calcular el intervalo de confianza para la diferencia de medias poblacionales del tiempo que duermen los estudiantes en días laborables y festivos, con nivel de confianza del 95%.

Primero guardamos en dos vectores las muestras de las horas que duermen los estudiantes en días laborables y en festivos:

```
> dormirL=encuesta$DORMIR
> dormirF=1.1*encuesta$DORMIR #Un 10% más que los laborables

> alfa=1-0.95
> d=dormirL-dormirF
> m=mean(d)
> s=sd(d)
> n=length(d)
> z=qnorm(1-alfa/2,0,1)
> (Li=m-z*(s/sqrt(n)))
[1] -0.6978706
> (Ls=m+z*(s/sqrt(n)))
[1] -0.6561835
```

El intervalo de confianza de la diferencia de media de las horas que duermen en laborables y festivos es [-0.6978706, -0.6561835].

- Calcular el intervalo de confianza con la función `z.test` del paquete BSDA.

```
> z.test(d, sigma.x=s ,conf.level=0.95)
95 percent confidence interval:
-0.6978706 -0.6561835
```

Podemos comprobar que se obtiene el mismo intervalo que aplicando las fórmulas.

c) ¿Existe una diferencia significativa entre las medias de las dos poblaciones?

Como el 0 no está incluido en el intervalo, se puede afirmar con un nivel de confianza del 95% que ***Sí hay diferencia significativa entre la media del tiempo que duermen los estudiantes los días laborables y los días festivos, y que la media del tiempo que duermen los días laborables es menor que la media del tiempo que duermen los días festivos***, porque los extremos de los intervalos son negativos.

6. Ejemplo: Intervalo de confianza para la diferencia de proporciones de estudiantes que tienen móvil Android en el turno de mañana y en el turno de tarde (muestras grandes e independientes)

ENUNCIADO

Mediante una encuesta se sabe que, en una muestra de 42 estudiantes del turno de mañana de la asignatura Estadística, 27 tienen teléfonos móviles con sistema operativo Android, y que en una muestra de 32 estudiantes del turno de tarde, 23 tienen también teléfono Android. La población es de 52 matriculados por la mañana y 56 por la tarde. Responder a las siguientes preguntas:

- Dibujar un diagrama con los intervalos de confianza de las proporciones poblacionales, con un nivel de confianza del 95%, para hacer una comparación visual.
- Calcular el intervalo de confianza para la diferencia de las proporciones poblacionales de estudiantes que tienen móvil Android en los turnos de mañana y tarde, con un nivel de confianza del 95%, utilizando fórmulas.
- Calcular el intervalo de confianza con la función `prop.test`.
- Dibujar el intervalo de confianza para la diferencia de proporciones poblacionales
- ¿Existe una diferencia significativa entre las proporciones de las dos poblaciones?

SOLUCIÓN

a) Dibujar un diagrama con los intervalos de confianza de las proporciones poblacionales, con un nivel de confianza del 95%, para hacer una comparación visual.

El intervalo de confianza de la proporción de estudiantes con móvil Android en el turno de mañana es:

```
> alfa=1-0.95

> soM=encuesta.mañana$SO
> soT=encuesta.tarde$SO

> nM=length(soM)
> nT=length(soT)

> nMA=length(soM[soM=="Android"])
> nTA=length(soT[soT=="Android"])

> pM=nMA/nM
> pT=nTA/nT
```

Como se hizo en la práctica anterior, se pueden calcular los intervalos aplicando fórmulas o usando la función `binom.confint()` del paquete `binom`.

Si se calculan con fórmulas.

```
> (z=qnorm(1-alfa/2,0,1))
[1] 1.959964

> (LiM=pM-z*sqrt(pM*(1-pM)/nM))
[1] 0.497946
> (LsM=pM+z*sqrt(pM*(1-pM)/nM))
[1] 0.7877682

> (LiT=pT-z*sqrt(pT*(1-pT)/nT))
[1] 0.5629712
> (LsT=pT+z*sqrt(pT*(1-pT)/nT))
[1] 0.8745288
```

Si se calculan con la función `binom.confint()` se obtienen los mismos intervalos:

```
> if (!require("binom")) install.packages("binom")
> library(binom)

> binom.confint(nMA, nM, conf.level = 0.95, methods = "asymptotic")
      method x  n      mean      lower      upper
1 asymptotic 27 42 0.6428571 0.497946 0.7877682


> binom.confint(nTA, nT, conf.level = 0.95, methods = "asymptotic")
      method x  n      mean      lower      upper
1 asymptotic 23 32 0.71875 0.5629712 0.8745288
```

Podemos dibujar los intervalos utilizando la función `ggplot()` del paquete `ggplot2`.

```
> if (!require("ggplot2")) install.packages("ggplot2")
> library(ggplot2)

> datos.grafico = data.frame (
  turno = c("Mañana", "Tarde"),
  prop = c(pM, pT),
  li = c(LiM, LiT),
  ls = c(LsM, LsT)
)

> ggplot(datos.grafico, aes(x=turno, y=prop)) + ylim(0,1) +
  xlab("Turno") + ylab("Proporción poblacional") +
  geom_point(size=3) +
  geom_text(aes(y = prop, label = round(prop,2)), hjust = 1.5, size = 3) +
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
color = "blue") +
  geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
  ggtitle("Intervalos al 95% para la proporción poblacional en cada turno") +
  theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```



Vemos que los dos intervalos se solapan, lo cual es un indicio de que sí va a haber coincidencia de proporciones, aunque lo tendremos que demostrar calculando el intervalo de la diferencia de proporciones.

b) Calcular el intervalo de confianza para la diferencia de las proporciones poblacionales de estudiantes que tienen móvil Android en los turnos de mañana y tarde, con un nivel de confianza del 95%, utilizando fórmulas.

Primero calculamos el tamaño de las muestras y de los estudiantes que usan Android en cada muestra.

Y se aplican las fórmulas:

$$L_i = \hat{p}_1 - \hat{p}_2 - z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

$$L_s = \hat{p}_1 - \hat{p}_2 + z_{\frac{\alpha}{2}} \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}$$

```
> z=qnorm(1-alfa/2,0,1)

> (Li=pM-pT-z*sqrt((pM*(1-pM)/nM)+(pT*(1-pT)/nT)))
[1] -0.2886515
> (Ls=pM-pT+z*sqrt((pM*(1-pM)/nM)+(pT*(1-pT)/nT)))
[1] 0.1368658
```

El intervalo de confianza de la diferencia de proporciones de estudiantes que tienen móvil Android en los turnos de mañana y tarde es [-0.2886515, 0.1368658]. Redondeando a dos decimales, es [-0.29, 0.14].

c) Calcular el intervalo de confianza con la función `prop.test`

```
> prop.test(c(nMA,nTA), c(nM,nT), conf.level = 1-alfa, correct=FALSE)
95 percent confidence interval:
-0.2886515  0.1368658
```


Podemos comprobar que se obtiene el mismo intervalo que aplicando las fórmulas.

d) Dibujar el intervalo de confianza para la diferencia de proporciones poblacionales

Se puede dibujar un diagrama con el intervalo usando la función `ggplot()`.

```
> datos.grafico = data.frame (
  conf = c("95%"),
  dif.prop = c(pM-pT),
  li = c(Li),
  ls = c(Ls)
)

> ggplot(datos.grafico, aes(x=conf,y=dif.prop)) + ylim(-0.5,0.5) +
  xlab("Confianza") + ylab("Diferencia de proporciones poblacionales") +
  geom_point(size=3) +
  geom_text(aes(y = dif.prop, label = round(dif.prop,2)), hjust = 1.5, size = 3)+
  geom_errorbar(aes(ymin=li, ymax=ls), width = 0.05) +
  geom_text(aes(y = li, label = round(li,2)), vjust = 1.5, hjust = 0.5, size = 3,
color = "blue") +
  geom_text(aes(y = ls, label = round(ls,2)), vjust = -0.5, hjust = 0.5, size = 3,
color = "red") +
  ggtitle("Intervalo al 95% para la diferencia de proporciones") +
  theme(plot.title = element_text(hjust = 0.5)) # Centra el título
```



e) ¿Existe una diferencia significativa entre las proporciones de las dos poblaciones?

Como el 0 está incluido en el intervalo $[-0.29, 0.14]$, se puede afirmar con un nivel de confianza del 95% que ***NO hay diferencia significativa entre las proporciones de móvil Android de los estudiantes de los turnos de mañana y tarde.***

7. Ejercicios propuestos

- 1) Mediante una encuesta, se sabe el tiempo en minutos del viaje a la Escuela Politécnica de 42 estudiantes del turno de mañana y de 32 estudiantes del turno de tarde de un curso de la asignatura Estadística del Grado en Ingeniería en Sistemas de Información de la Universidad de Alcalá, de una población de 52 matriculados en el turno de mañana y 56 en el turno de tarde. Si se supone que las calificaciones tienen una distribución Normal, responder a la siguiente pregunta:
 - a. Calcular el intervalo de confianza para la diferencia de medias poblacionales del tiempo del viaje a la Escuela de los turnos de mañana y tarde con nivel de confianza del 95%. ¿Existe una diferencia significativa entre las medias de las dos poblaciones?

- 2) Mediante la encuesta se sabe el tiempo en minutos del viaje de ida a la Escuela Politécnica de 74 estudiantes de una población de 108 matriculados. Se ha averiguado que el viaje de regreso dura un 10% menos que el de ida. Si se supone que el tiempo del viaje, tanto de ida como de vuelta, tiene una distribución Normal, responder a la siguiente pregunta:
 - a. Calcular el intervalo de confianza para la diferencia de medias poblacionales del tiempo de viaje de ida y del tiempo de viaje de vuelta de los estudiantes, con nivel de confianza del 95%. ¿Existe una diferencia significativa entre las medias de las dos poblaciones?

- 3) Mediante la encuesta se sabe que en una muestra de 42 estudiantes del turno de mañana, 13 tienen una línea telefónica contratada con las compañías Jazzte/Orange/Simyo, y que en una muestra de 32 estudiantes del turno de tarde, 13 tienen también una línea telefónica contratada con las compañías Jazzte/Orange/Simyo. La población es de 52 matriculados por la mañana y 56 por la tarde. Responder a las siguientes preguntas:
 - a. Calcular el intervalo de confianza para la diferencia de las proporciones poblacionales de estudiantes que tienen una línea telefónica contratada con las compañías Jazzte/Orange/Simyo en los turnos de mañana y tarde, con un nivel de confianza del 95%. ¿Existe una diferencia significativa entre las proporciones de las dos poblaciones?